# BSAC Module7

## 바이오 인공지능 SW

2021

KPC

# RNN

# 순환 신경망 (RNN) – CNN

- 합성곱 신경망(CNN)
  - 2차원(공간) 필터에서 좋은 성과 입증, 이미지 학습 분야에서 널리 사용

- 그러나 CNN은 시간적인 차이를 두고 연속적으로 발생하는 데이터 분석에는 성능이 부족
  - 연속된 단어로 구성되는, 문장 분석, 자연어 처리, 자동 번역, 시계열 데이터 분석 등

- 이런 데이터에는 순환신경망(Recurrent Neural Network)이 잘 동작

# 순환 신경망 (RNN) – 텍스트 처리

- 기존 텍스트 분석에서 BOW를 이용
  - 문장 내에 어떤 단어들이 존재하는지는 파악하지만
  - 단어의 배열 정보는 사라지고 이용하지 못함

- 단어의 순서 정보도 분석하려면
  - BoW, 단어 벡터의 도입만으로는 부족
  - 단어의 발생 순서 정보를 활용할 수 있는 신경망 모델을 사용해야 한다
  - 이를 위해서 순환신경망(RNN)이 널리 사용

# 순환 신경망 (RNN) – 과거 정보 기억

- MLP, CNN에서는 입력 데이터를 한 번 신경망에 통과시키면 데이터가 한 방향으로만 흘러가는 구조

- RNN은 과거의 데이터에서 추출한 정보를 지속적으로 모델 내에서 저장하고 이를 학습에 재사용
  - 사람이 대화를 나누거나 책을 읽을 때 단어를 순차적으로 듣게 되고 최신의 입력 단어들 뿐 아니라 과거의 정보를 계속 내부적으로 사용해야 하는 것과 같은 원리

- 즉, CNN에서는 과거의 기억(상태정보)을 사용하지 않지만 RNN은 과거의 기억을 사용하는 구조를 제공

# 순환 신경망 (RNN) – 응용

- 주요 응용
  - 음성인식
  - 텍스트 분석
  - 자연어 처리
  - 챗봇
  - 감성 분석
  - 언어 모델링(language modeling)

  등에 널리 사용

# RNN 기본 구조

- RNN은 loop가 들어 있고
- 과거의 데이터가 미래에 영향을 줄 수 있는 구조

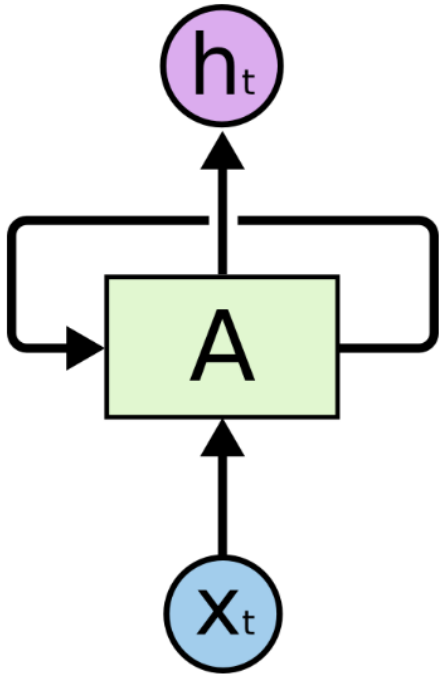

# RNN unrolled

- 좌측
  - 순환신경망 하나의 유닛(셀)을 그린 것
  - 현재의 상태값이 다음번 상태값을 구하는데 순환적으로 사용
- 우측
  - 이해하게 쉽게 시간축으로 나누어 그린 것

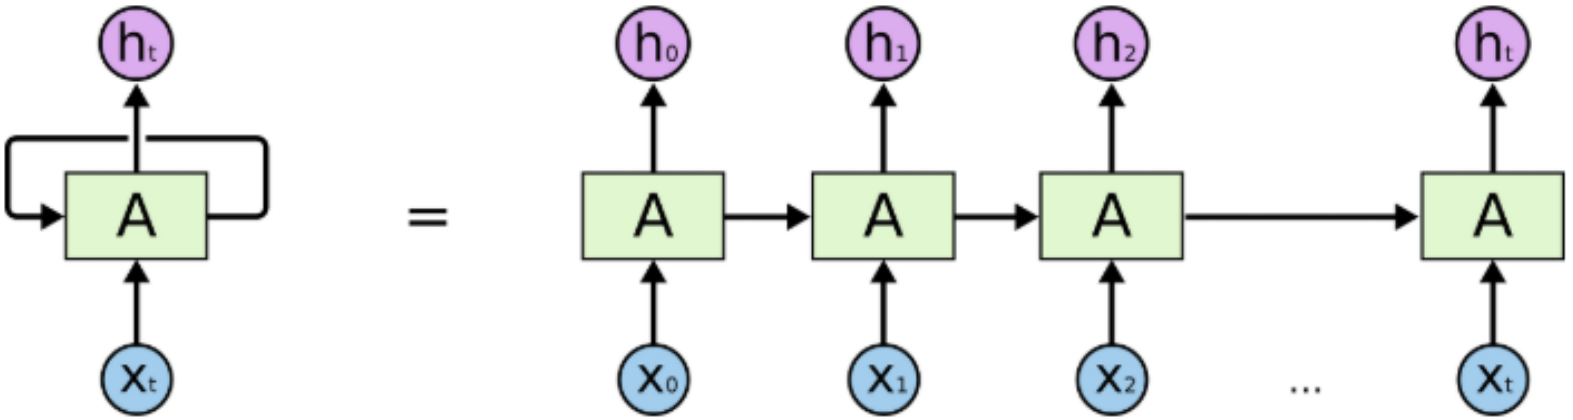

# RNN vs FF 신경망

RNN has internal hidden state which can be fed back to network

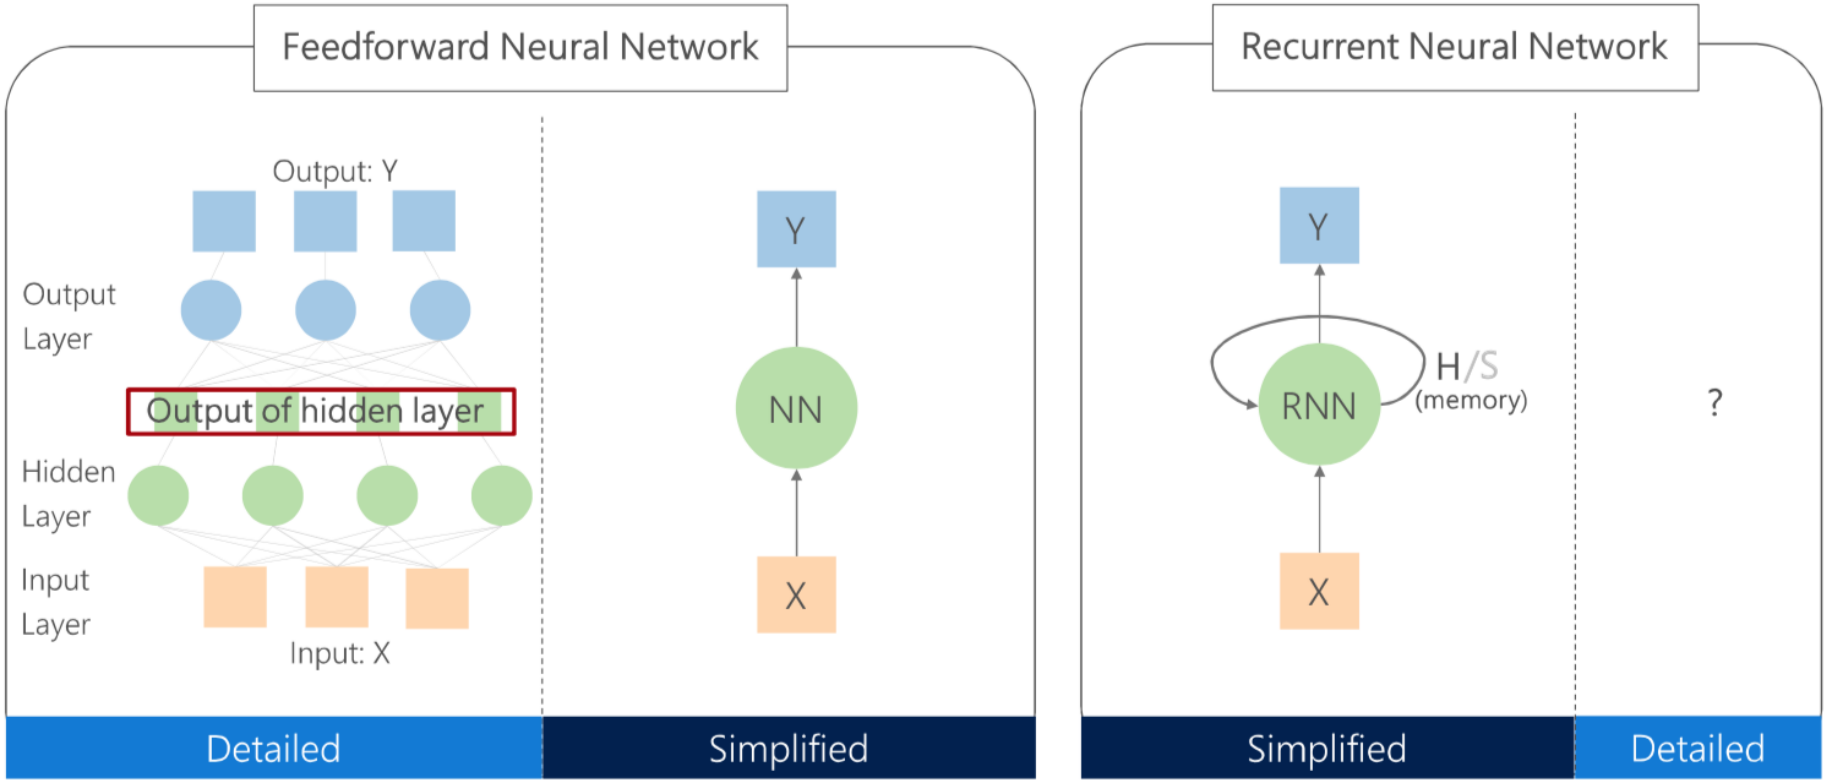

# RNN unrolled

- 매 timesteps에 동일한 가중치를 사용

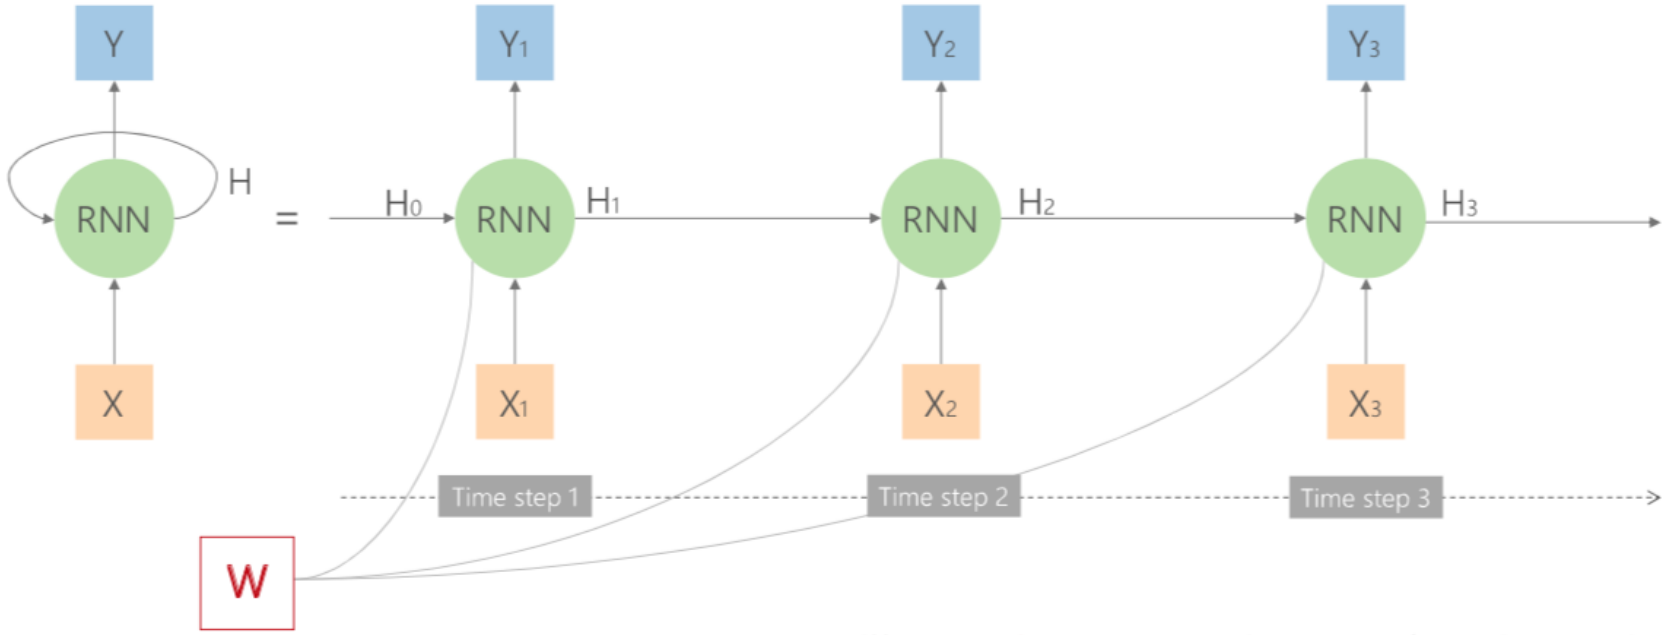

# 상세 동작

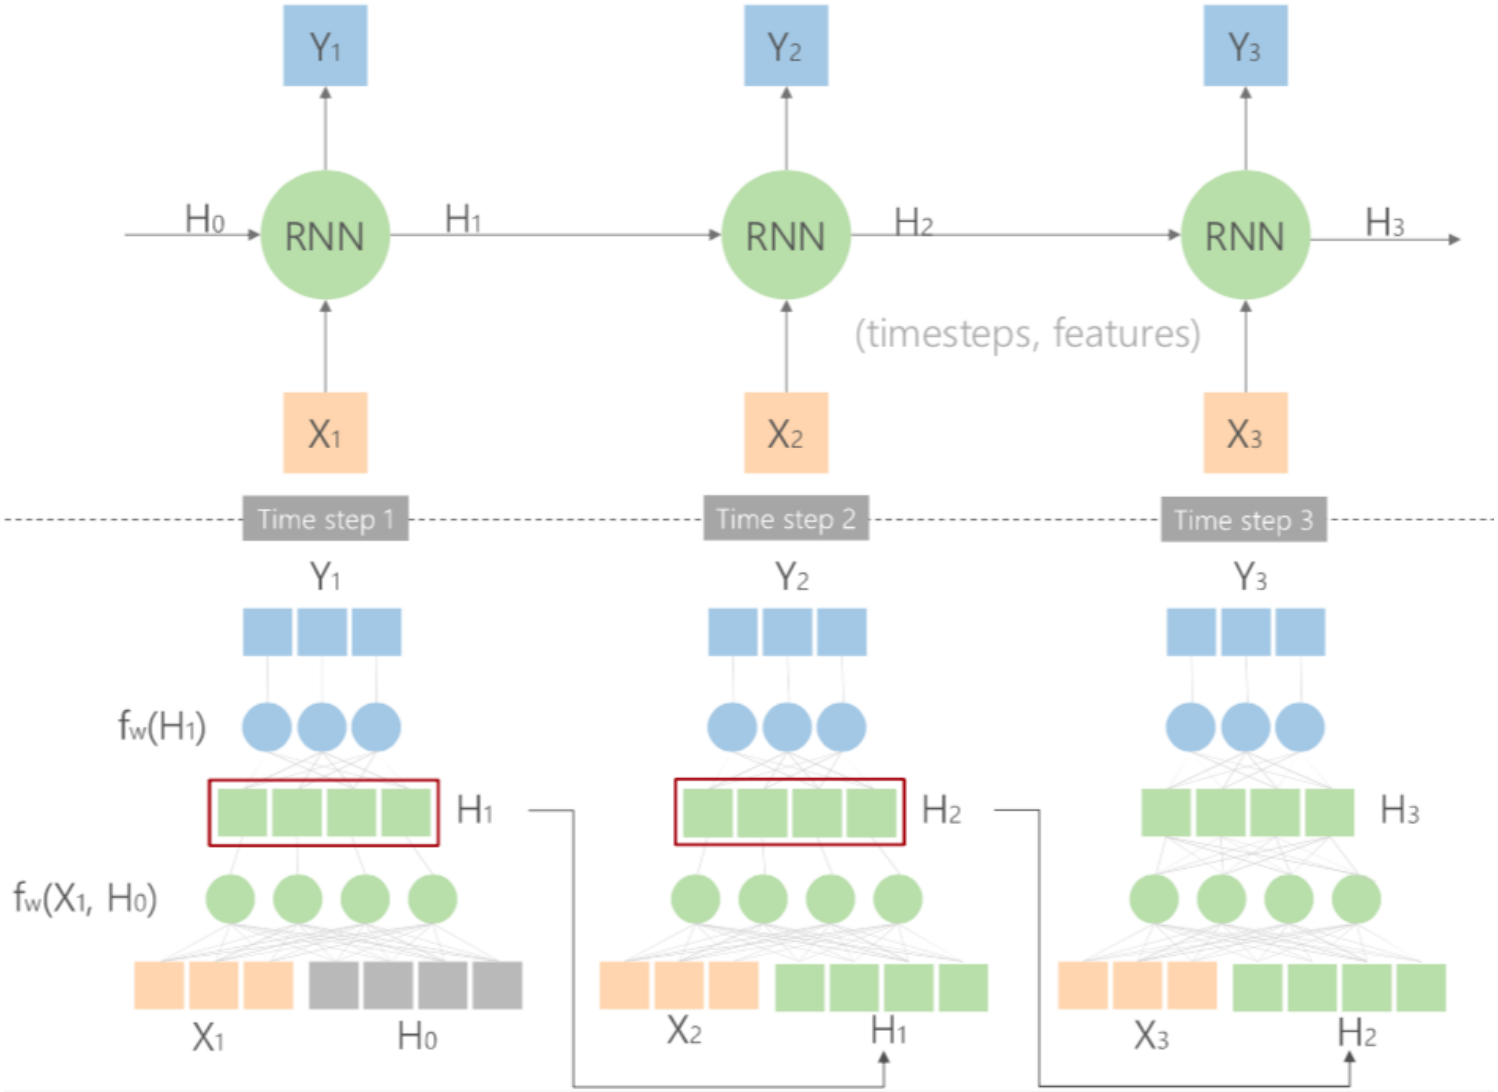
Y1
Y2
Y3
H0
RNN
H1
RNN
H2
RNN
H3
(timesteps, features)
X1
X2
X3
Time step 1
Time step 2
Time step 3
Y1
Y2
Y3
fw(H1)
H1
H2
H3
fw(X1, H0)
X1
H0
X2
H1
X3
H2

# RNN 기본 구조

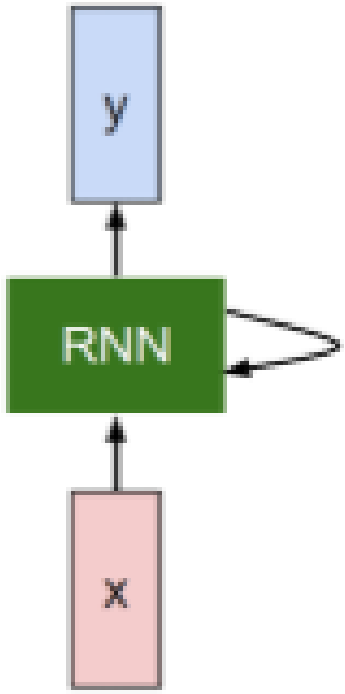

# RNN 기본 구조 – 내부 상태 보유

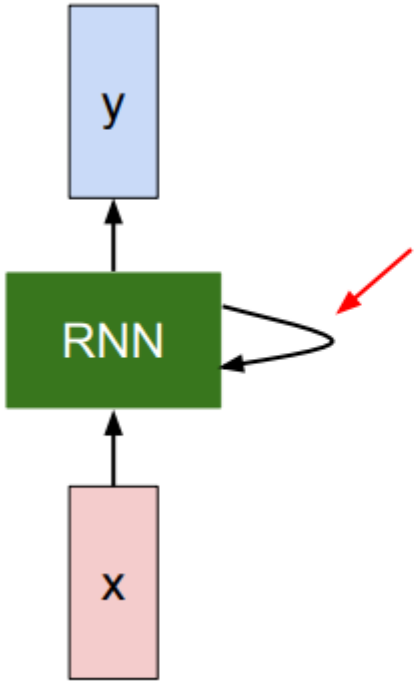


Key idea: RNNs have an "internal state" that is updated as a sequence is processed

# RNN 기본 구조 – 내부 상태 보유

We can process a sequence of vectors **x** by applying a **recurrence formula** at every time step:

$$h_t = f_W(h_{t-1}, x_t)$$

new state

some function with parameters W

old state

input vector at some time step

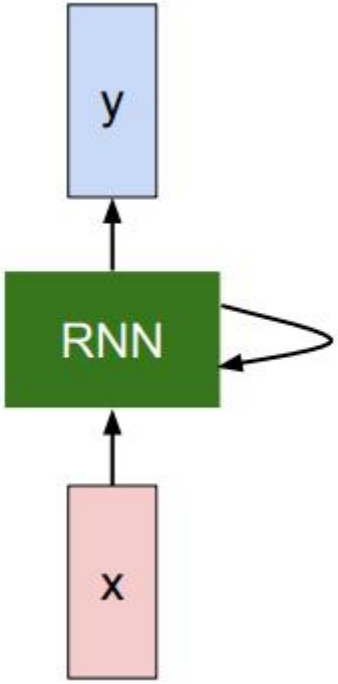

# 기본 순환 신경망

- **현재의 출력**
  - 현재의 상태값으로부터 구한다

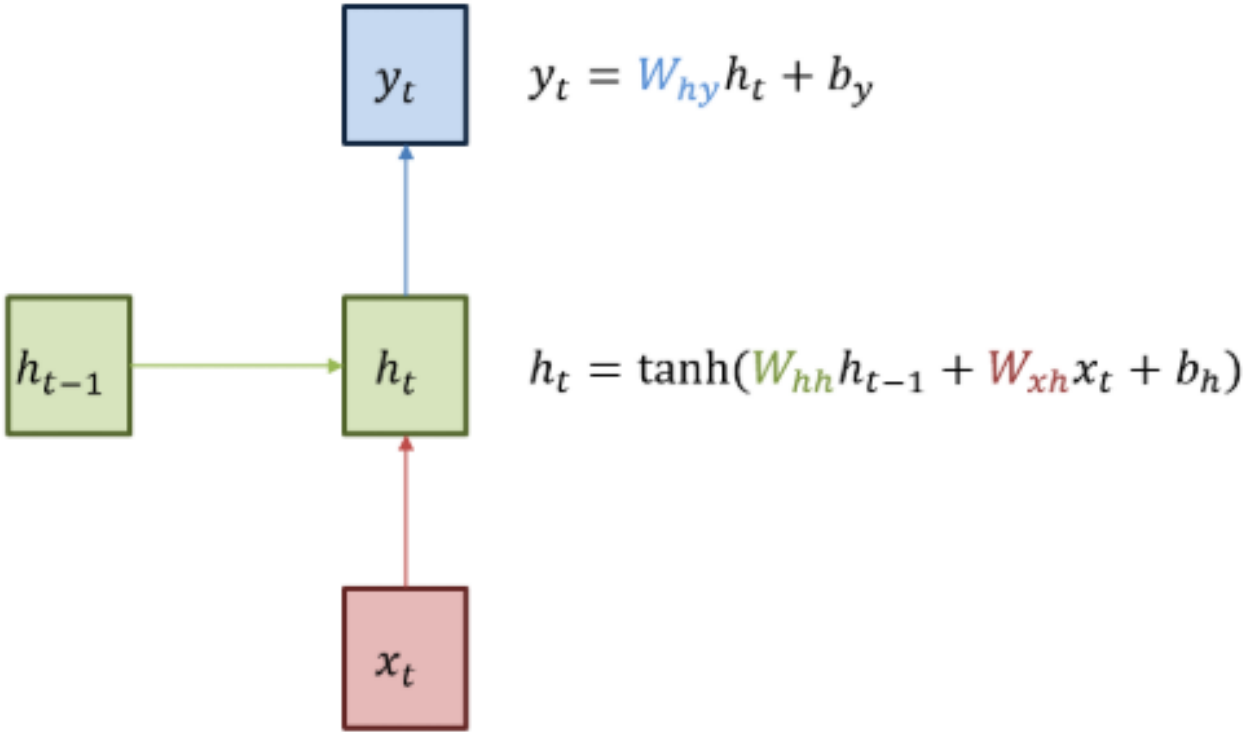

# 기본 순환 신경망 – 과거 정보 사용

- 모델의 현재 상태값을 얻기 위해서
  - **현재의 입력정보** 뿐 아니라 모델의 **이전의 상태 정보**도 동시에 사용

- 수식으로 표현

$$H_t = UX_t + WH_{t-1}$$

  - X(t) : 현재 입력 정보
  - H(t-1) : 이전 상태 정보
  - U, V : 가중치(계수) 매트릭스

- 이로써 과거의 정보를 내부적으로 재사용

# 기본 순환 신경망 – 과거 정보 사용

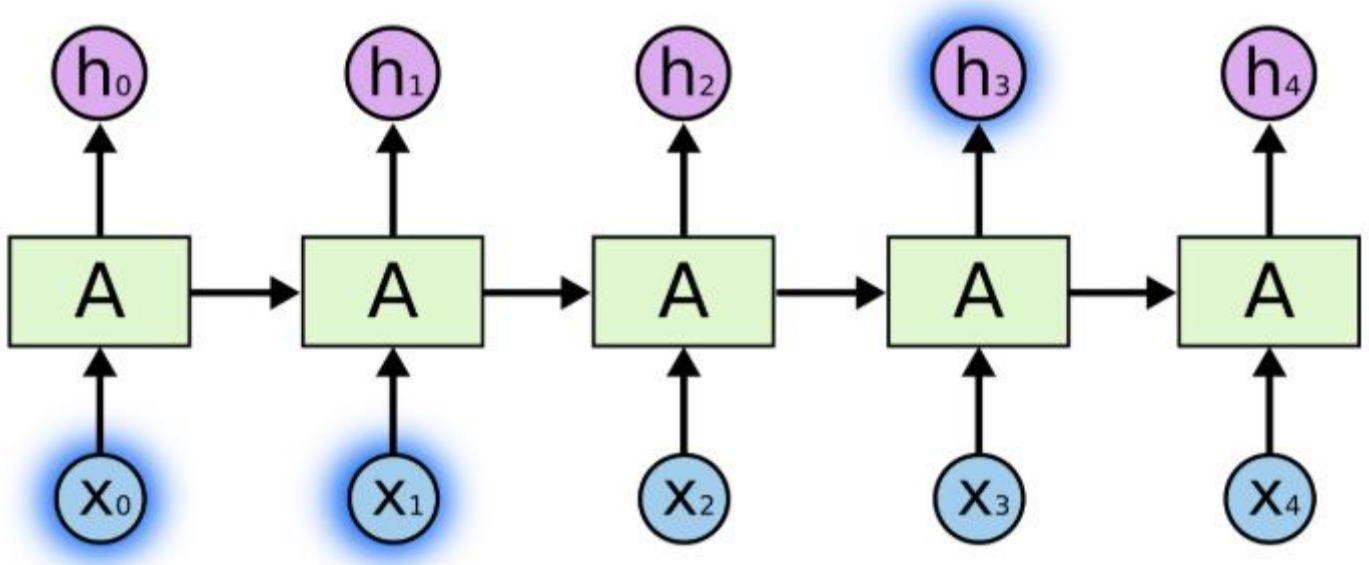

# 기본 순환 신경망 – 동일한 가중치 사용

- 모든 step에서 동일한 필터(가중치)를 사용
  - 계수 U, V, W는 시각(t)의 함수가 아니라, 모든 step에서 동일

- 순환신경망을 학습
  - 가중치 매트릭스 U, V, W의 값이 최적화되도록 학습하는 것

# 기본 순환 신경망 – 상태 , 출력

- **현재 상태  상태 활성화 함수**
  - Tanh함수를 주로 사용 (참고로 CNN에서는 ReLU)
  - W : 과거의 상태 정보를 얼마나 많이 활용하는지를 결정

$$H_t = \tanh(WH_{t-1} + UX_t)$$

- **현재의 출력**
  - 현재의 상태값으로부터 구한다

$$y_t = VH_t + c$$

# 기본 순환 신경망 – 상태 , 출력

- 우리가 다른 사람의 말을 듣고 대답을 한다면,
  - 먼저 머릿속에 상대방의 말을 이해하는 상태를 만들어야 하고(즉, $H_t$)
  - 이 상태에 기반하여 출력($y_t$)를 만들어내는 것과 유사한 개념

- 입력(X)의 단위
  - 한 단어일 수도 있고
  - 10개의 단어일 수도 있고, 한 문장일 수도

- 현재 출력을 구하는데 이전의 상태 정보를 순환적으로 사용
  - 결국 최초의 상태값을 포함해서 오래된 상태 정보를 조금이라도 활용한다고 볼 수 있다

# 기본 순환 신경망 – 기울기 소실 문제

- 과거의 오래된 신호를 적은 비중으로 일괄적으로 반영하면 신호의 업데이트가 너무 적어져서 기울기 소실 문제가 발생

- 과거의 신호를 너무 많이 반영하면 신호가 발산하는 문제가 발생

- 해결책
  - LSTM(Long-Short Term Memory) 기법이 널리 사용
  - 오랜 기간 중요도를 유지할 정보와 그럴 필요 없이 망각해야 할 신호를 구분하여 따로 처리

# RNN 기본 모델 유형

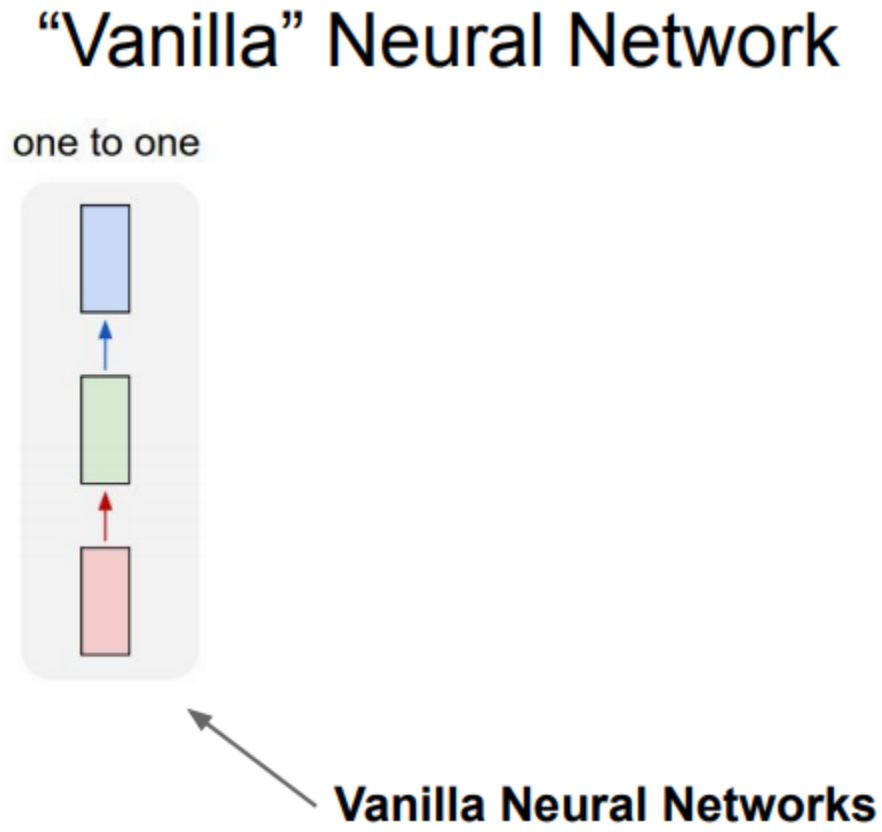

# RNN 기본 모델 유형

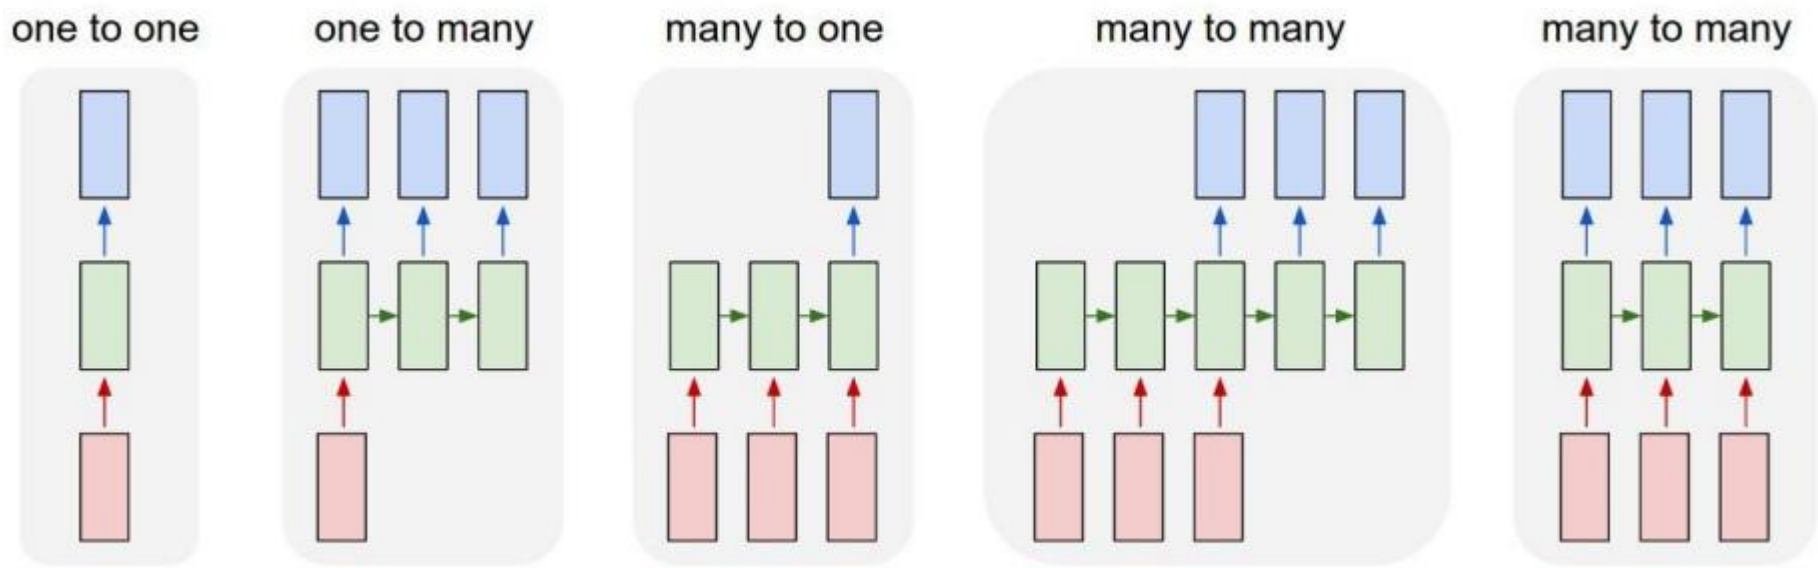


e.g. **Image Captioning**
image -> sequence of words

# RNN 기본 모델 유형

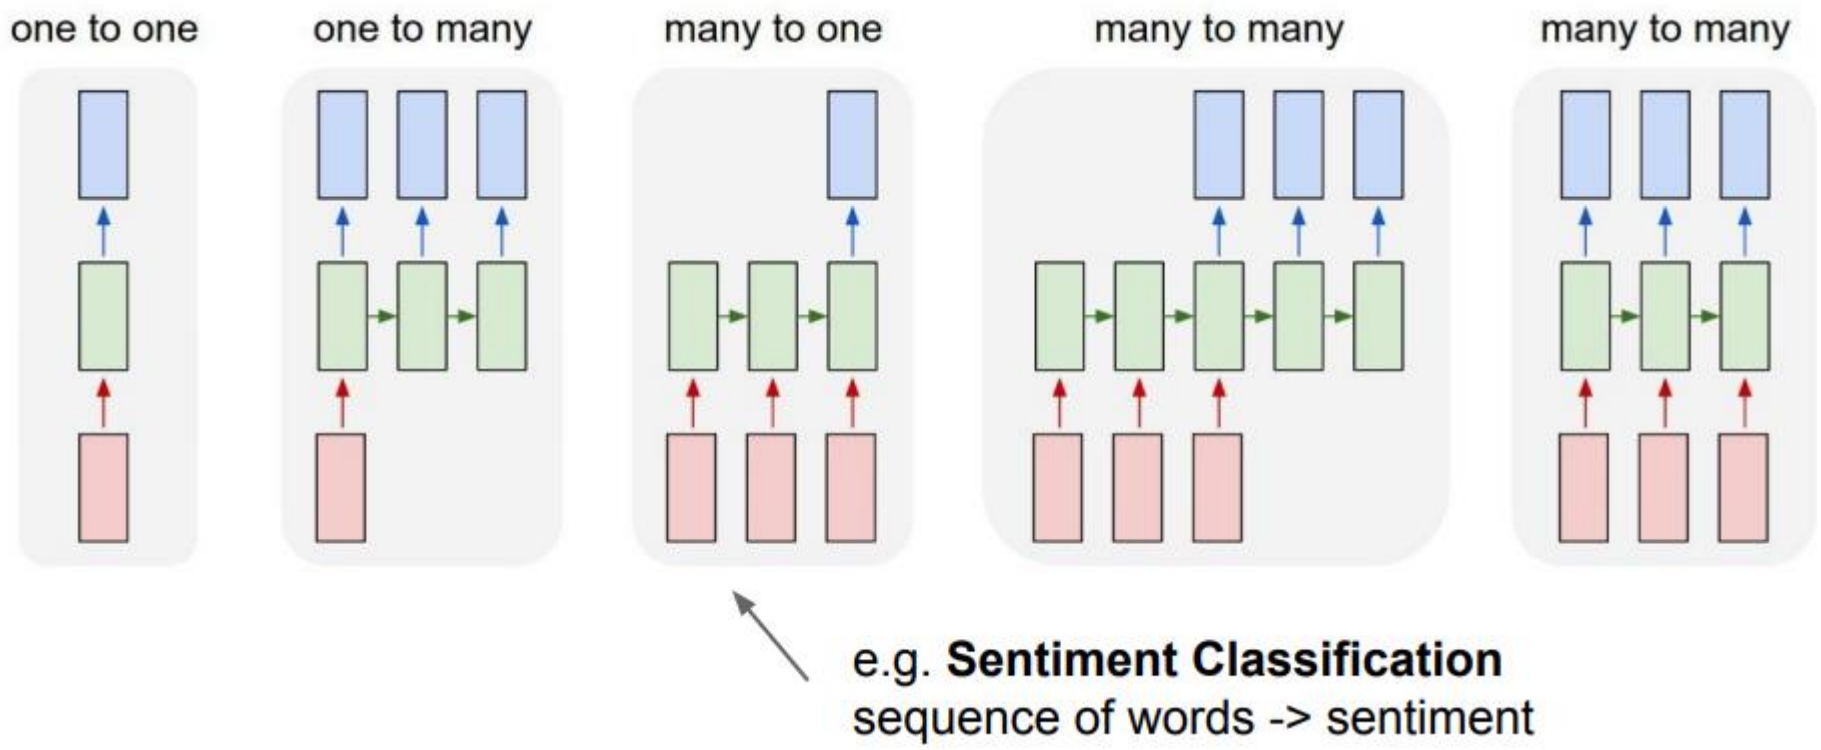
one to one
one to many
many to one
many to many
many to many
e.g. **Sentiment Classification**
sequence of words -> sentiment

# RNN 기본 모델 유형

- 언어 모델(language model)
  - 일정 크기의 문장을 입력하면 이에 상응하여 한 글자씩 다음 위치에 있는 글자나 단어를 출력
  - 매 입력마다 출력이 발생

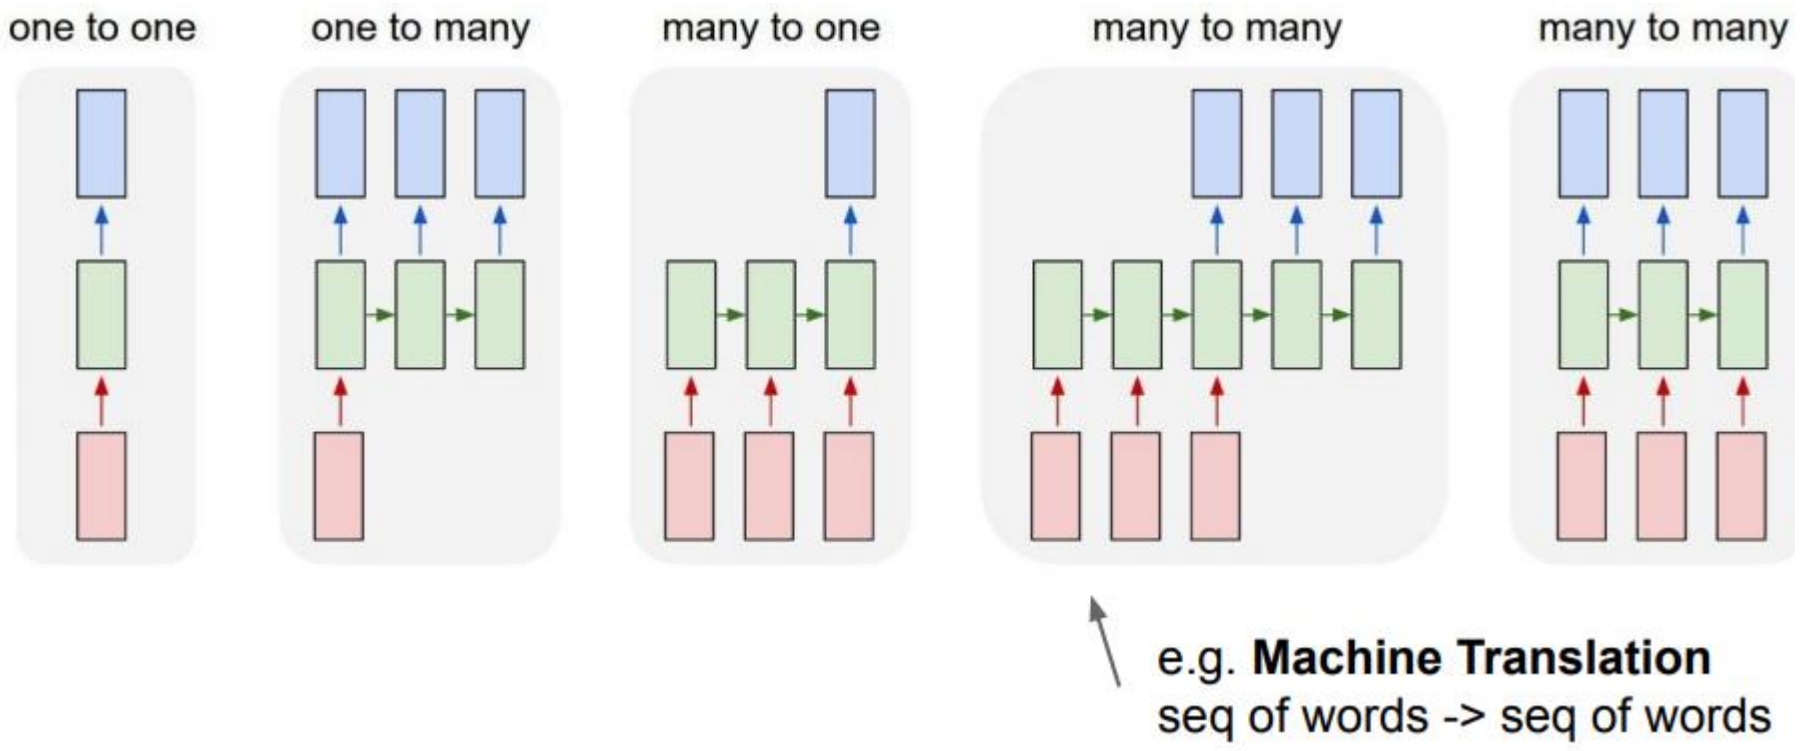

# RNN 기본 모델 유형

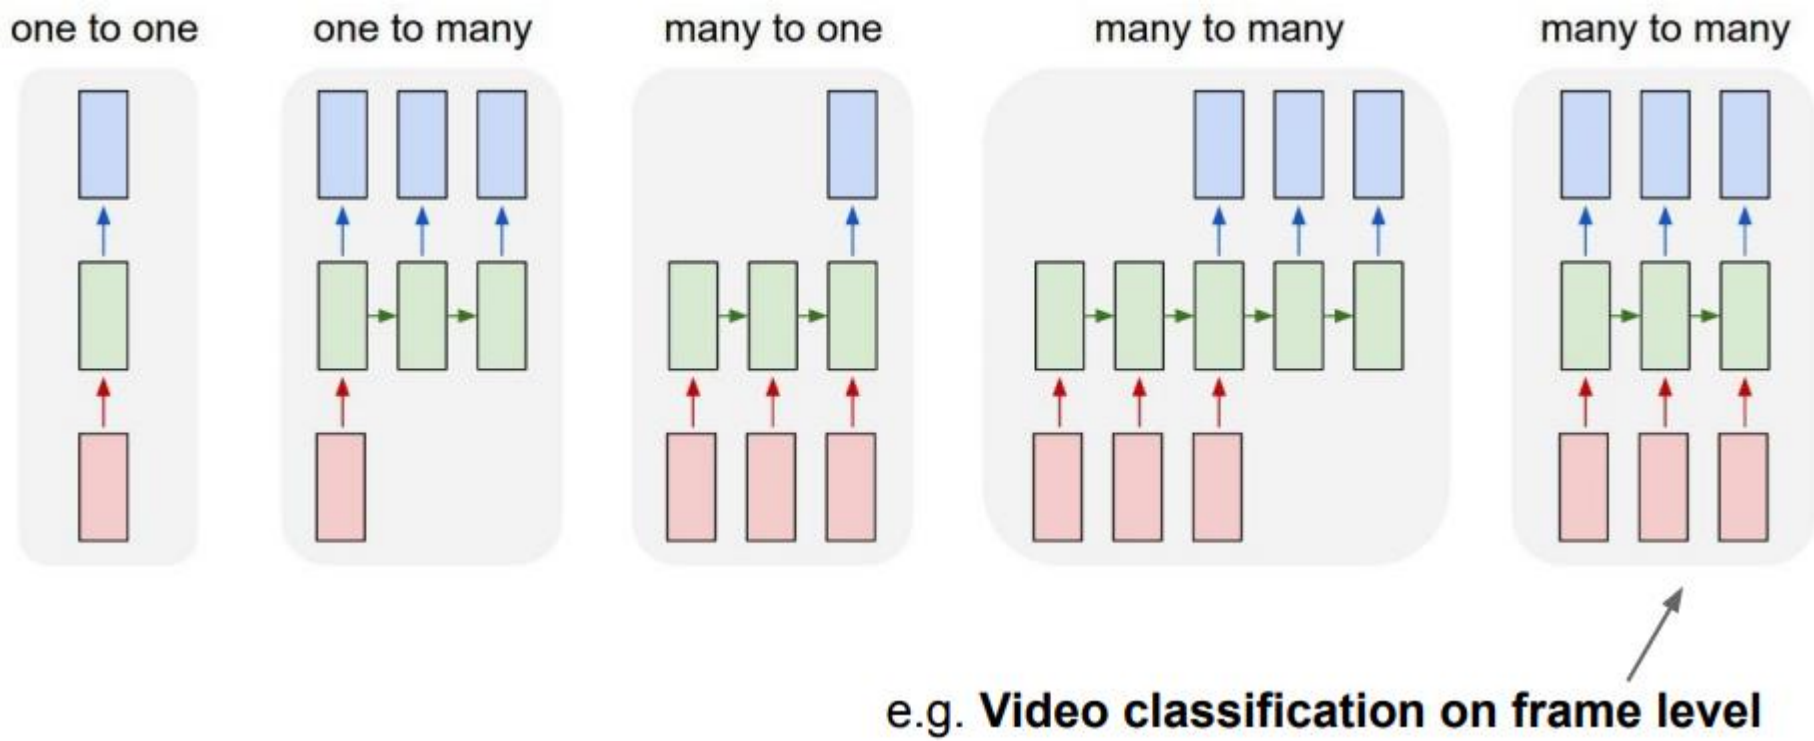
one to one
one to many
many to one
many to many
many to many
e.g. **Video classification on frame level**

# RNN 모델 – 인코더-디코더 (many to many)

- 인코더-디코더 모델
  - 일종의 시퀀스-시퀀스 모델
  - 하나의 문장을 모두 듣고 이를 번역 또는 다른 대답을 하는 모델 등에 사용

- 시퀀스-시퀀스 모델
  - 하나의 시퀀스를 모드 입력하면 그 이후에 출력이 시퀀스 형태로 나오는 것

- 인코딩 된 결과는 디코더로 전달
  - context vector 또는 machine thought 벡터 형태로 전달

- teacher forcing
  - 예측한 출력이 아니라 실제 레이블 값으로 학습시키는 방법

# RNN 학습 – BPTT

- 경사하강(gradient descent) 방식의 학습을 주로 사용
  - 오류역전파 방식을 이용
  - 모델의 출력과 레이블 사이에 오류가 발생하며 이로부터 계산된 손실의 경사값을 앞 단쪽의 계층으로 전달하여 가중치를 조절

- 학습에 의해서 가중치 매트릭스 W, U, V가 업데이트 되는데 RNN에서는 모든 타임 스텝에서 동일한 가중치를 사용한다는 것을 주의해야 한다.

- 즉, 현재의 경사(gradient) 변화는 과거 스텝의 계산에도 영향을 미친다. 이러한 현상을 BPTT(backpropagation through time)이라고 함

# RNN – 순전파

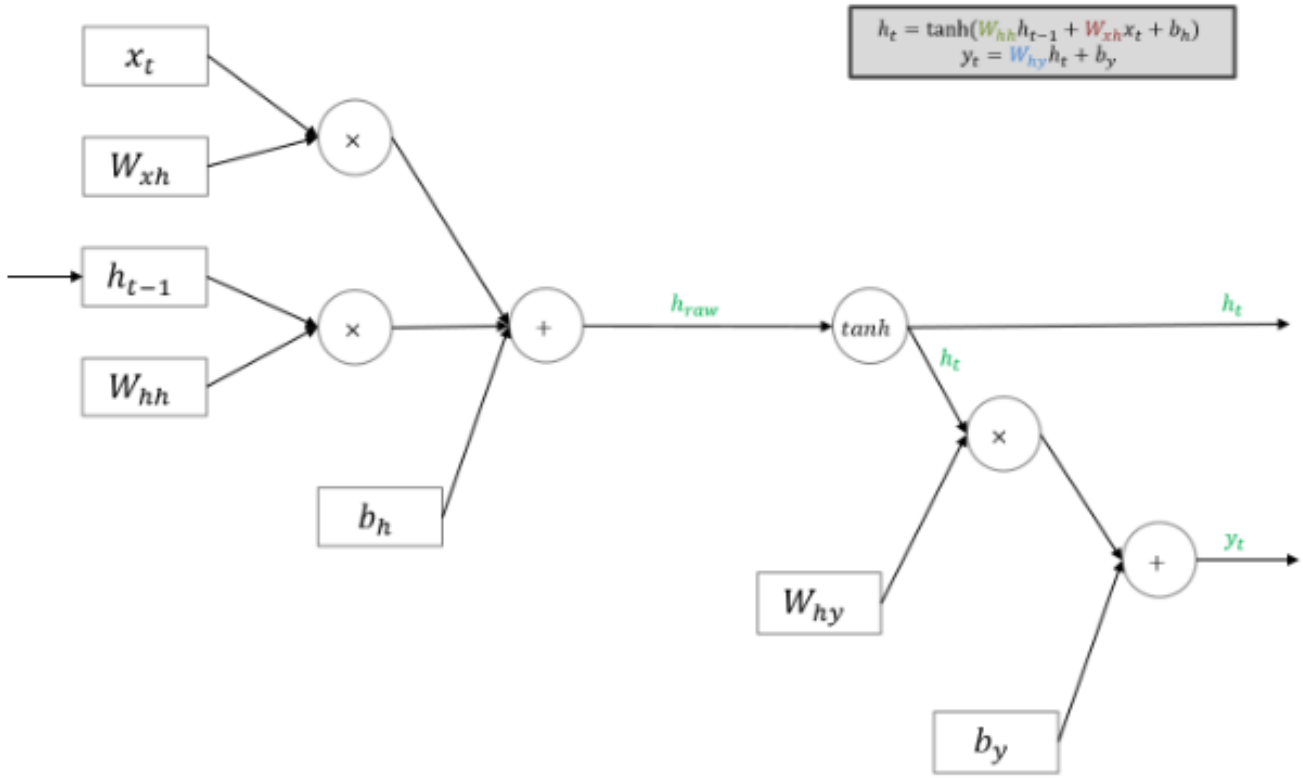
$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t + b_h)$
$y_t = W_{hy}h_t + b_y$
$x_t$
$W_{xh}$
$h_{t-1}$
$W_{hh}$
$b_h$
×
×
+
$h_{raw}$
tanh
$h_t$
$h_t$
×
$W_{hy}$
+
$y_t$
$b_y$

# RNN – 역전파

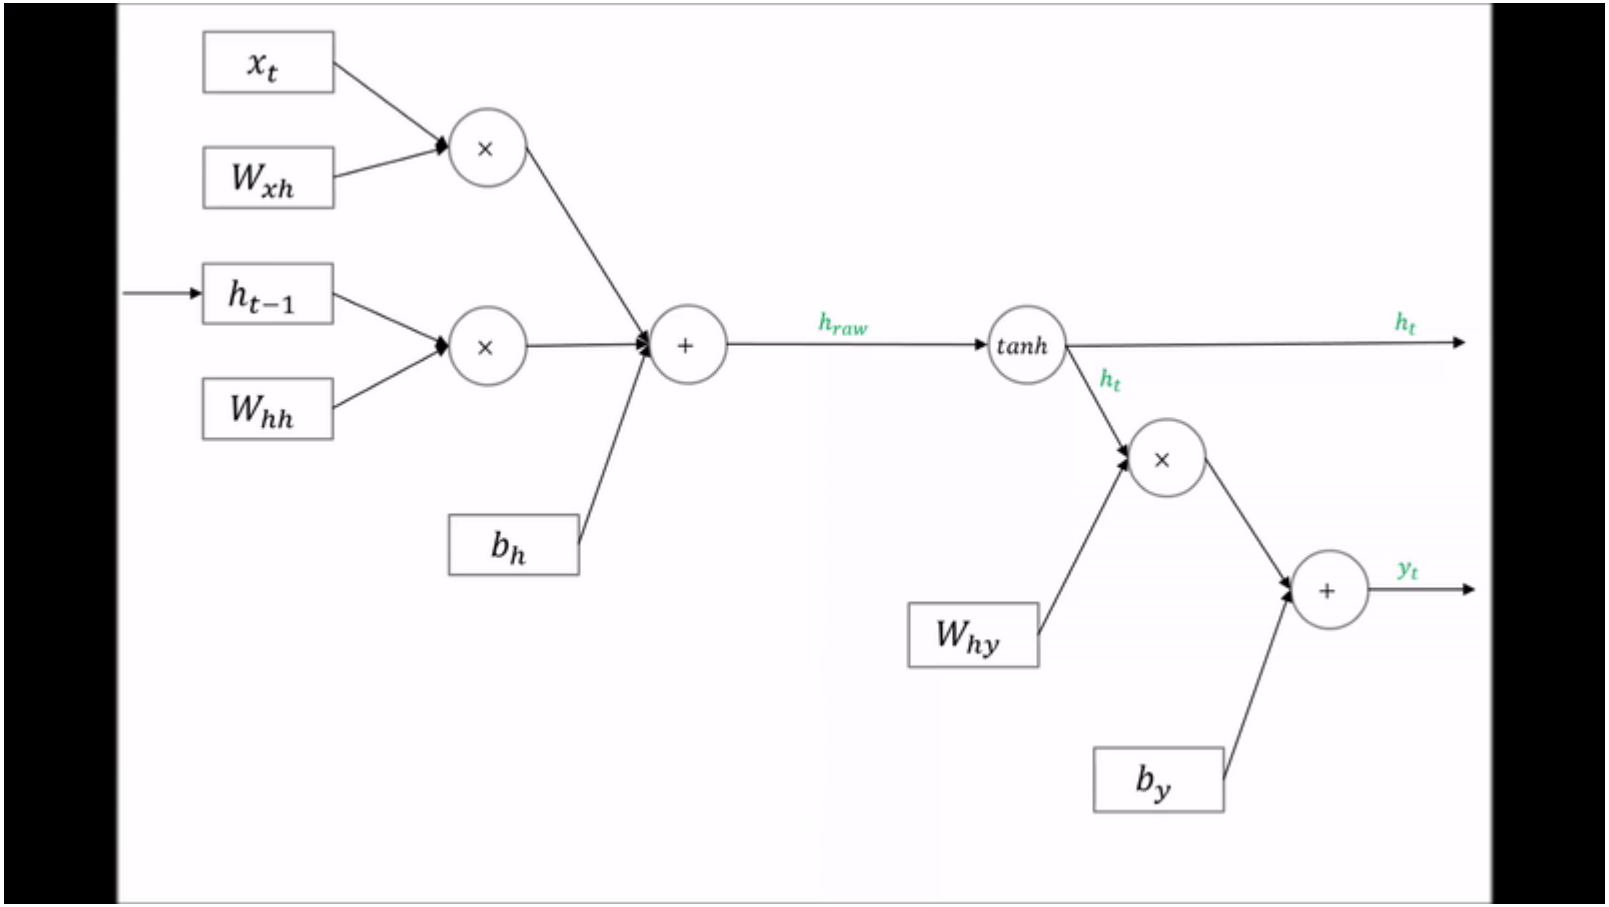

# RNN의 문제점

- RNN에서 여러 계층을 거치는 경우, 예를 들어 단어가 수십 개로 된 문장을 해석하는 경우, 오차 역전파를 하면서 경사값이 거의 사라지거나 또는 너무 큰 값으로 발산하여 RNN이 제대로 동작하지 못하기 쉽다
  - 오래된 정보를 모두 중요시하면 정보가 너무 많이 축적되어 발산할 우려
  - 오래된 정보를 약하게 반영하면 오래되었지만 중요한 정보를 캐치하지 못하는 즉, 소실되는 우려

- 이를 해결하기 위해서
  - LSTM(Long-Short Term Memory), GRU 기법이 제안
  - LSTM에서는 오랜기간 중요도를 유지할 정보와 그럴 필요 없이 망각해야 할 신호를 구분하여 따로 처리

# LSTM

# LSTM – 개념

- 단순 RNN 구조 (케라스의 SimpleRNN)
  - 실제로는 **경사 소실-발산** 등의 문제로 인해 잘 사용하지 않는다
  - 즉, 오래된 정보가 마지막 출력단에서는 매우 약해져서 학습에 사용하기 부족해진다. 따라서 step 수가 늘면 학습이 잘 되지 않는다.

- LSTM
  - RNN의 단점을 극복하기 위해서 제안
  - 여러 스텝 앞의 정보를 놓치지 않고 따로 뒷단으로 보내주는 **채널**을 하나 더 추가(오래된 정보가 스텝을 지나면서 사라지지 않고 뒤에 영향을 미치도록 하는 것이 목적)
  - 우리가 대화를 할 때에도 바로 최근의 단어들을 듣고 뜻을 파악하지만 오래 전에 한 말을 통해서 전체적인 맥락이나 목적 등을 꾸준히 파악하는 것과 같은 의미
  - 즉, 시퀀스로 입력되는 데이터의 단기(short) 정보와 함께, 오래된(long) 정보를 병행해서 사용하고 학습한다는 의미로 LSTM이라는 이름을 붙임

# LSTM – Vanishing gradient problem

- RNN은 관련 정보와 그 정보를 사용하는 지점 사이의 거리가 멀 경우
  - 역전파 시, gradient 정보가 점차 줄어 들어 학습능력이 현저히 저하

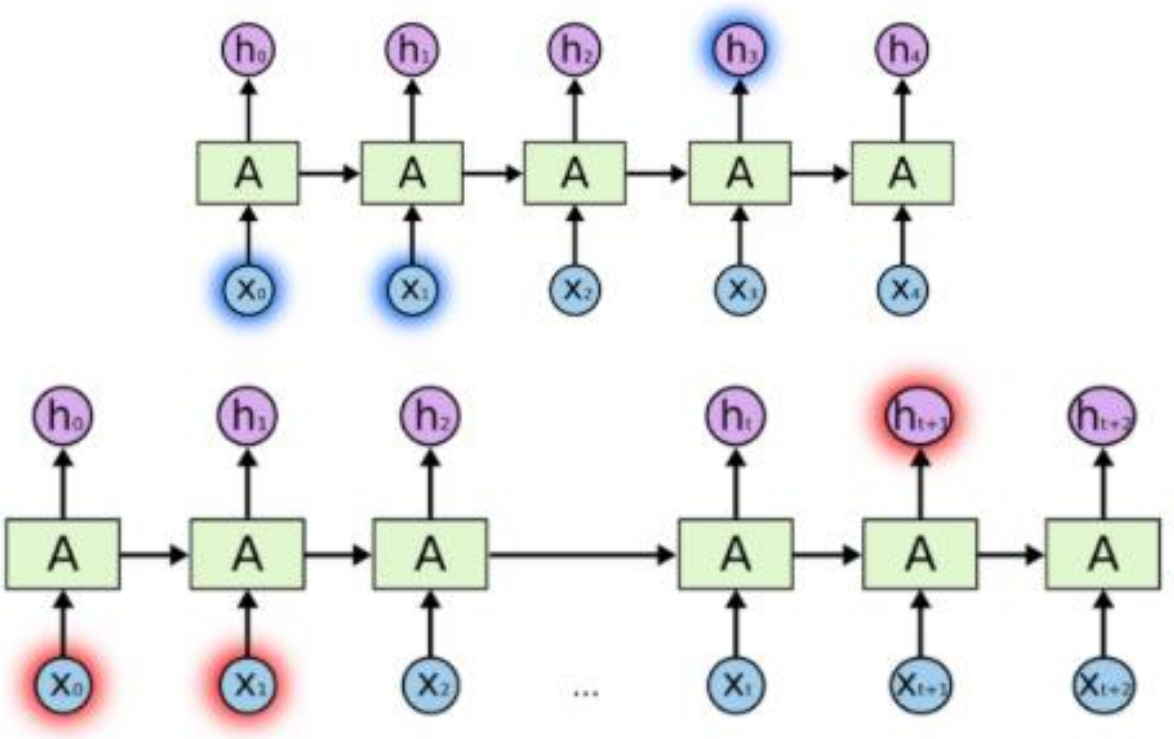

# LSTM – 개념

- 각 cell은 장, 단기 2개의 채널 사용
  - 단기적으로 학습한 정보가 전달되는 채널
    (현재의 입력 정보와 상태 정보에서는 필요한 부분을 선택)
  - 장기적으로 살아남아 전달되는 채널
    (과거의 전달 정보에서도 필요한 정보를 필터링하는 작업을 수행)

- LSTM에서 선택해야 할 하이퍼 파라미터
  - 임베딩 차원
  - L출력 차원

- LSTM의 장점
  - 문서 번역
  - 질의 응답(QA)
  - 대화 서비스 (챗봇)

  등에서 좋은 성능

# LSTM – 개념

- 내부 히든 정보 외에 Cell state 정보를 추가로 전달
  - 선형 자기연결 정보

- 망각(forget), 입력(input), 출력(output) 게이트를 사용
  - 장기적인 상호작용을 학습시키는데 유용
  - 새롭고 관련성이 있는 정보를 선호하여 기억하도록 하고, 관련이 적은 정보를 잊도록 학습

# LSTM – 구조

- 오래된 정보를 전달하는(carry) 별도의 채널이 있다
- 각 셀에서는
  - 입력 신호(x), 이전 단계의 상태 정보(t), 그리고 이 전달 정보(c) 세 가지 정보의 가중치 합을 구하고
  - 활성화 함수를 통과하여 출력(t)을 만든다

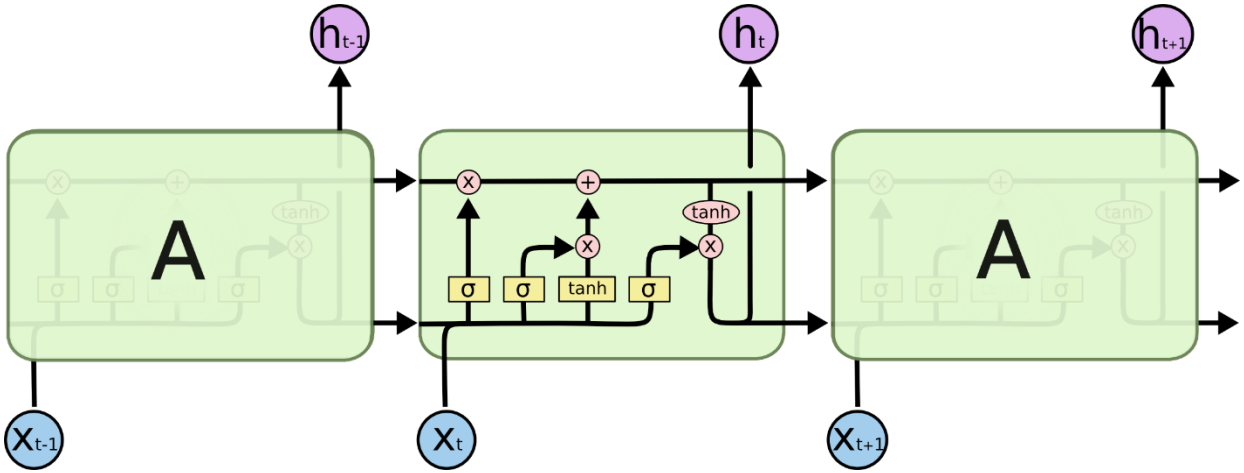

# LSTM – RNN과의 비교

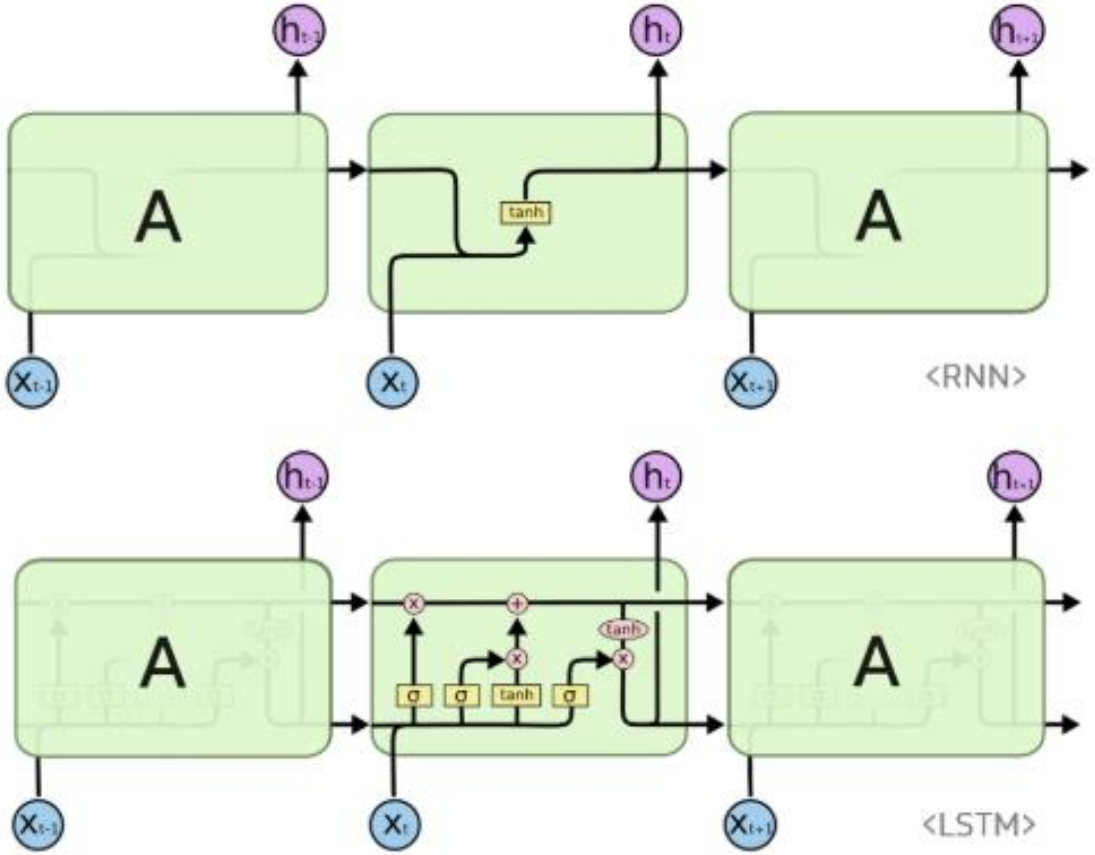

# LSTM – RNN과의 비교

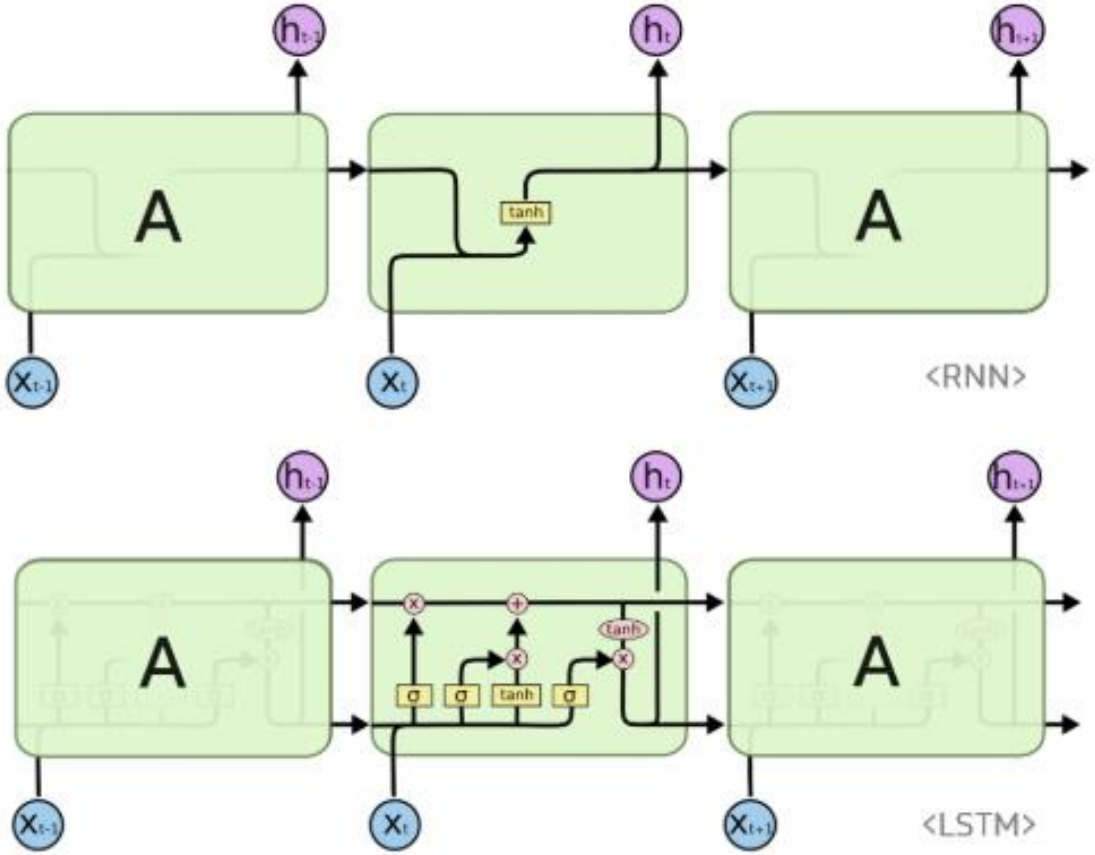

# LSTM – cell state

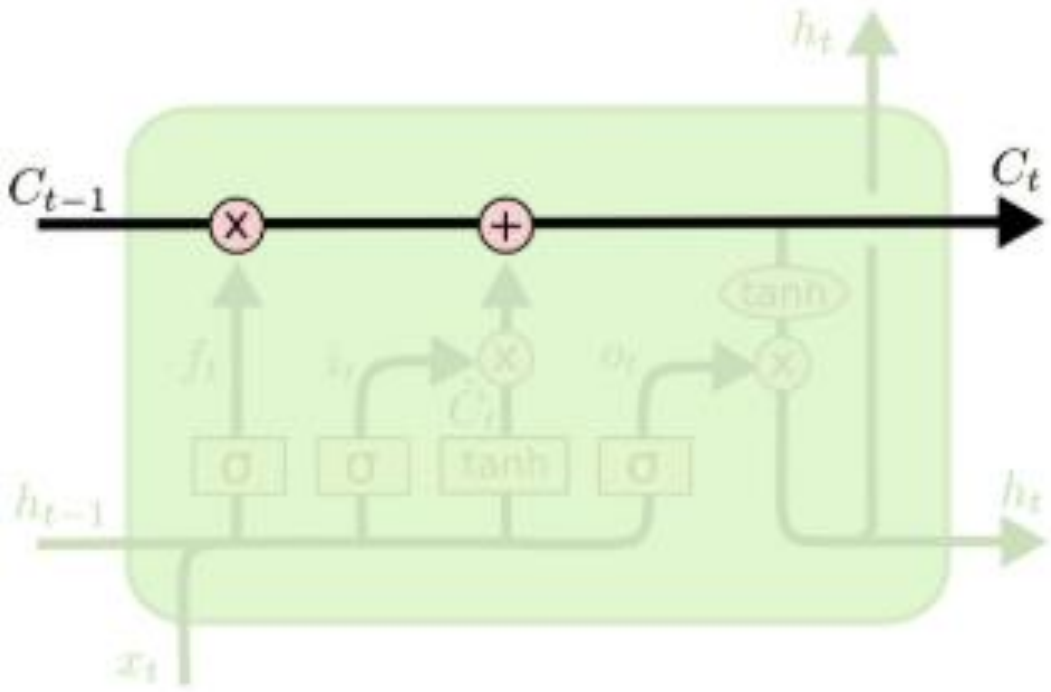

# LSTM – forget gate

- cell state로부터 어떤 정보를 버릴 것인지를 결정
  - ➢ sigmoid layer 사용

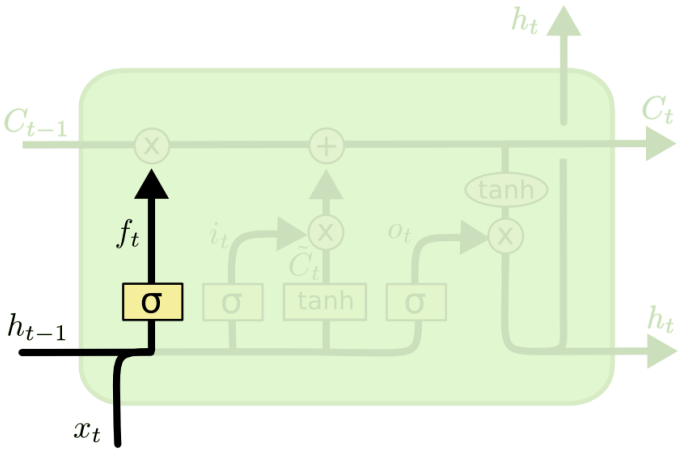


$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \; + \; b_f\right)$$

# LSTM – input gate

- 앞으로 들어오는 새로운 정보 중 어떤 것을 cell state에 저장할 것인지를 결정

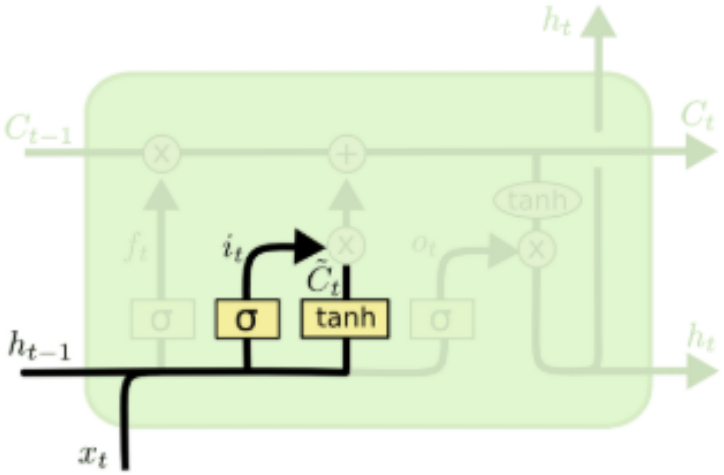


$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] \; + \; b_i\right)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] \; + \; b_C)$$

# LSTM – input gate

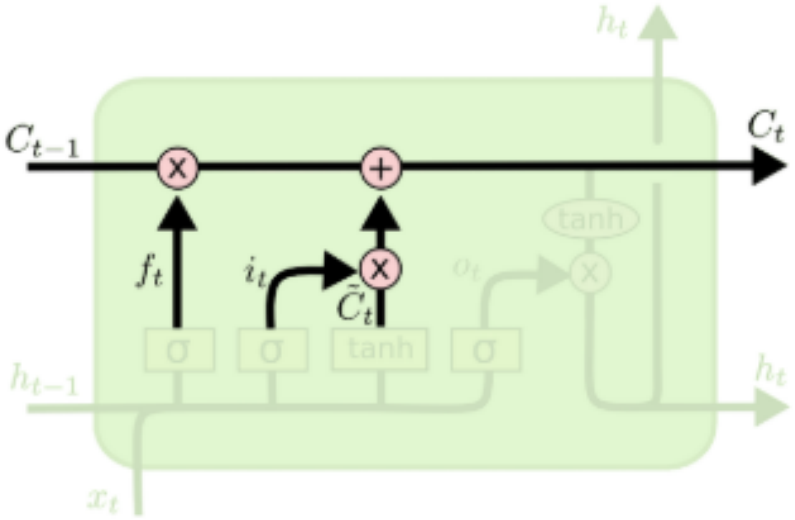


$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

# LSTM – output gate

- 무엇을 output으로 내 보낼 지를 결정

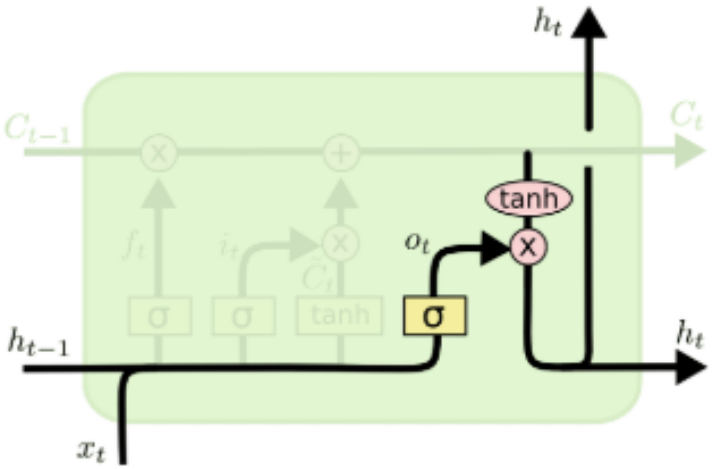


$$o_t = \sigma\left(W_o\left[h_{t-1}, x_t\right] + b_o\right)$$

$$h_t = o_t * \tanh\left(C_t\right)$$

# GRU – 구조

- LSTM과 같은 기능을 수행, 간단한 구조 (2014)
  - 응용에 따라서 LSTM보다 성능이 우수하기도 하고 떨어지기도 함

- 2개의 게이트 사용
  - 리셋 게이트
  - 업데이트 게이트 : forget과 input 게이트를 합한 기능을 수행

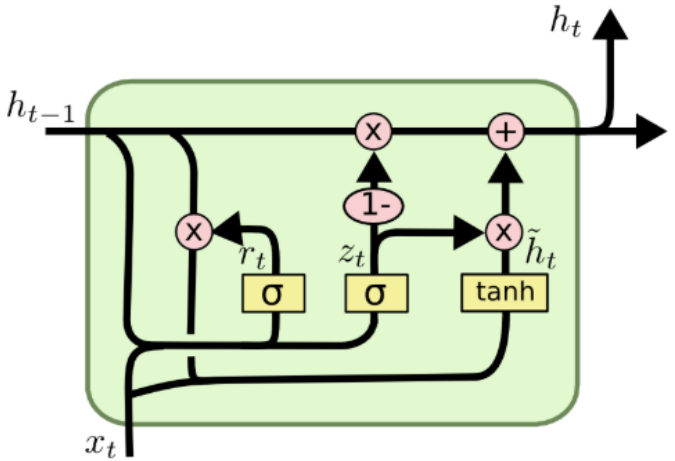


$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$

$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$

$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

# 양방향 RNN

- 시퀀스를 양쪽 방향으로 처리하여(즉, 두 번 프로세싱함), 한쪽 방향으로만 볼 때 놓치기 쉬운 패턴을 찾아보는 방법

- 즉, 현재에서 과거로의 추정과 함께 과거로부터 현재로의 추정을 동시에 진행하여 이 중에 좋은 패턴을 활용한다는 개념

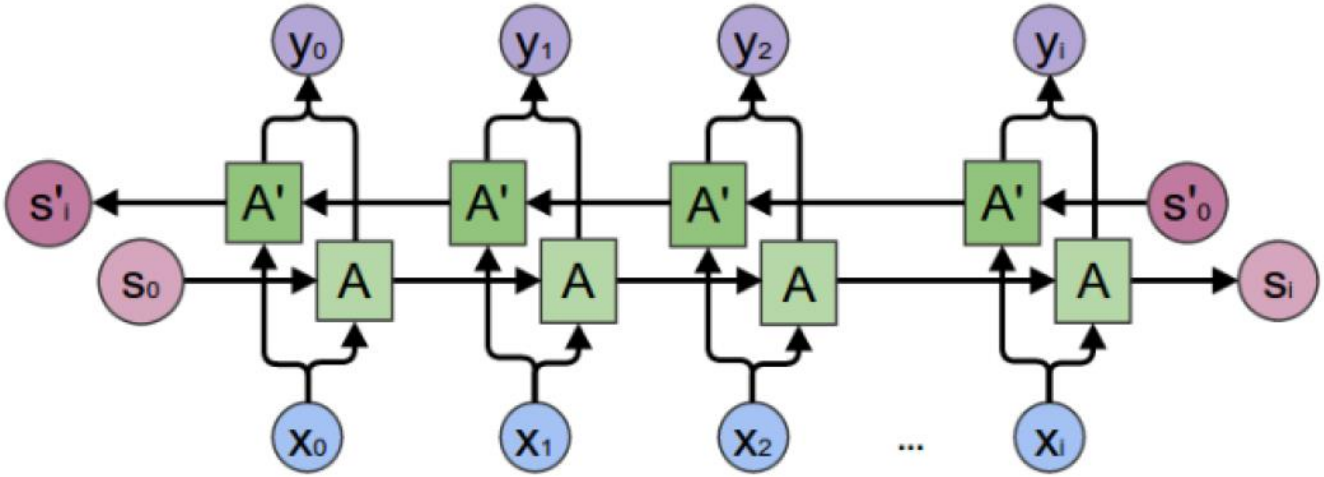

# 양방향 RNN

- 이러한 양방향 RNN이 항상 잘 성능을 개선하는 것은 아니나 좋은 성능을 나타내는 경우가 있다. 특히 자연어 처리에서 좋은 성능을 낸다.
- 문장과 같이 단어의 나열의 경우에 반대 방향으로 단어의 순서를 뒤집어서 예측하는 경우도 비슷한 성능을 보임
- 이는 언어에서 반대의 순으로 말을 하여도 컴퓨터를 거의 비슷하게 학습할 수 있다고 볼 수 있다
- 같은 정보를 다른 방법으로 표현하는 것을 활용하여 앙상블을 취하면 더 좋은 성능을 낼 수 있다는 가정에서 양방향 RNN을 도입
- Keras에서는 양방향 RNN을 구축하기 위한 Bidirectional 계층을 지원한다. 그러나 두 배 많은 파라미터를 사용하게 되어 과대적합이 될 가능성도 더 높아진다

# 텍스트 처리 – 원 핫 (One-hot) 인코딩

- **원 핫 인코딩**
  - **토큰**에 고유 번호를 배정
  - 모든 고유번호 위치의 한 컬럼만 1, 나머지 컬럼은 0인 **벡터**로 표시

텍스트: "어제 러시아에 갔다가 러시아 월드컵을 관람했다"

토큰 사전: { "어제" :0, "러시아" :1, "갔다" :2, "월드컵" :3, "관람" :4}

원핫 인코딩:

어제 = [1, 0, 0, 0, 0]
러시아 = [0, 1, 0, 0, 0]
갔다 = [0, 0, 1, 0, 0]
월드컵 = [0, 0, 0, 1, 0]
관람 = [0, 0, 0, 0, 1]

# BOW (Bag of Word, 단어 모음)

- 원핫 인코딩 방식으로 단어(토큰)을 표현하면
  - 단어의 수가 적을 때에는 문제가 안되지만
  - 단어가 모두 10만개이면
    - 모든 단어가 항목이 10만개인 (0과 1로 구성된) 벡터로 표시
  - 주어진 텍스트가 20개의 단어로 구성되어 있다면
    - 20 x 100,000개 크기의 벡터가 필요
- 텍스트 분석은 "문장" 을 단위로 하는 경우가 많다
- 단어 모음(BOW) 방식 : 한 문장을 하나의 벡터로 만드는 방법
  - 한 문장을 단어 사전 크기의 벡터로 표현하고 그 문장에 들어 있는 단어의 컬럼만 1로, 단어가 없는 컬럼은 모두 0으로 표현
- 먼저 단어 사전을 만들고 각 문장에 어떤 단어가 들어 있는지 조사하여 해당 컬럼만 1로, 나머지는 0으로 코딩

# BOW

- 단어 사전: { “어제” :0, “오늘” :1, “미국” :2, “러시아” :3,
  “갔다” :4, “축구” :5, “월드컵” :6, “올림픽” :7,
  “관람” :8, “나는” :9, …, “중국” :4999 }
- Text_1: “어제 러시아에 갔다가 러시아 월드컵을 관람했다” 를 BOW로 표현하면

| 문장번호 | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | … | 4998 | 4999 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Text_1 | 1 | 0 | 0 | 1 | 1 | 0 | 1 | 0 | 1 | 0 | 0 | 0 | 0 | 0 |
| Text_2 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| Text_3 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| Text_4 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 1 | 0 |
| … | | | | | | | | | | | | | | |
| Text_50 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |

# 문서-단어 행렬

- 문장 단위로 어떤 단어들이 있는지를 나타내는 BOW의 확장
- 문서(document) 단위로 어떤 단어들이 있는지를 표현
- 같은 단어가 여러번 등장하면 1 이상의 값을 갖는다

| 문서번호 | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | ... | 4998 | 4999 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Doc_1 | 1 | 2 | 3 | 1 | 4 | 0 | 2 | 0 | 1 | 3 | 0 | 0 | 0 | 0 |
| Doc_2 | 0 | 0 | 0 | 0 | 2 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 2 | 0 |
| Doc_3 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 3 | 0 | 0 | 0 | 0 | 1 |
| Doc_4 | 4 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 4 | 0 | 1 | 0 |
| ... | | | | | | | | | | | | | | |
| Doc_100 | 0 | 2 | 0 | 0 | 0 | 0 | 1 | 4 | 0 | 1 | 0 | 0 | 0 | 0 |

# td-idf

- term frequency-inverse document frequency
- tf : 단어가 각 문서에서 발생한 빈도
- df(document frequency) : 그 단어가 등장한 '문서' 의 빈도
- 적은 문서에서 발견될수록 가치 있는 정보
- 많은 문서에 등장하는 단어일수록
  - 일반적인 단어
  - 이러한 공통적인 단어는 tf가 크다고 하여도 비중을 낮추어야 분석이 제대로 이루어질 수 있다.
- 따라서 단어가 특정 문서에만 나타나는 희소성을 반영하기 위해서 idf(df의 역수)를 tf에 곱한 값을 tf 대신 사용

# 단어 임베딩의 정의

- 앞에서 소개한 세 가지 텍스트 코딩 방식인 원핫 인코딩, BOW(단어모음), 문서-단어 행렬방식은 단어마다 고유번호를 배정하여 사용
- 그러나 이 고유 번호 숫자에는 아무런 의미가 들어 있지 못하며 단지 인덱스의 성격만 갖는다.
- 단어를 인덱싱이 아니라, 의미 있는 숫자 들의 집합, 즉, 벡터로 표현하는 방법이 단어 임베딩 (Word Embeding)이다.

# Featurized representation: word embedding

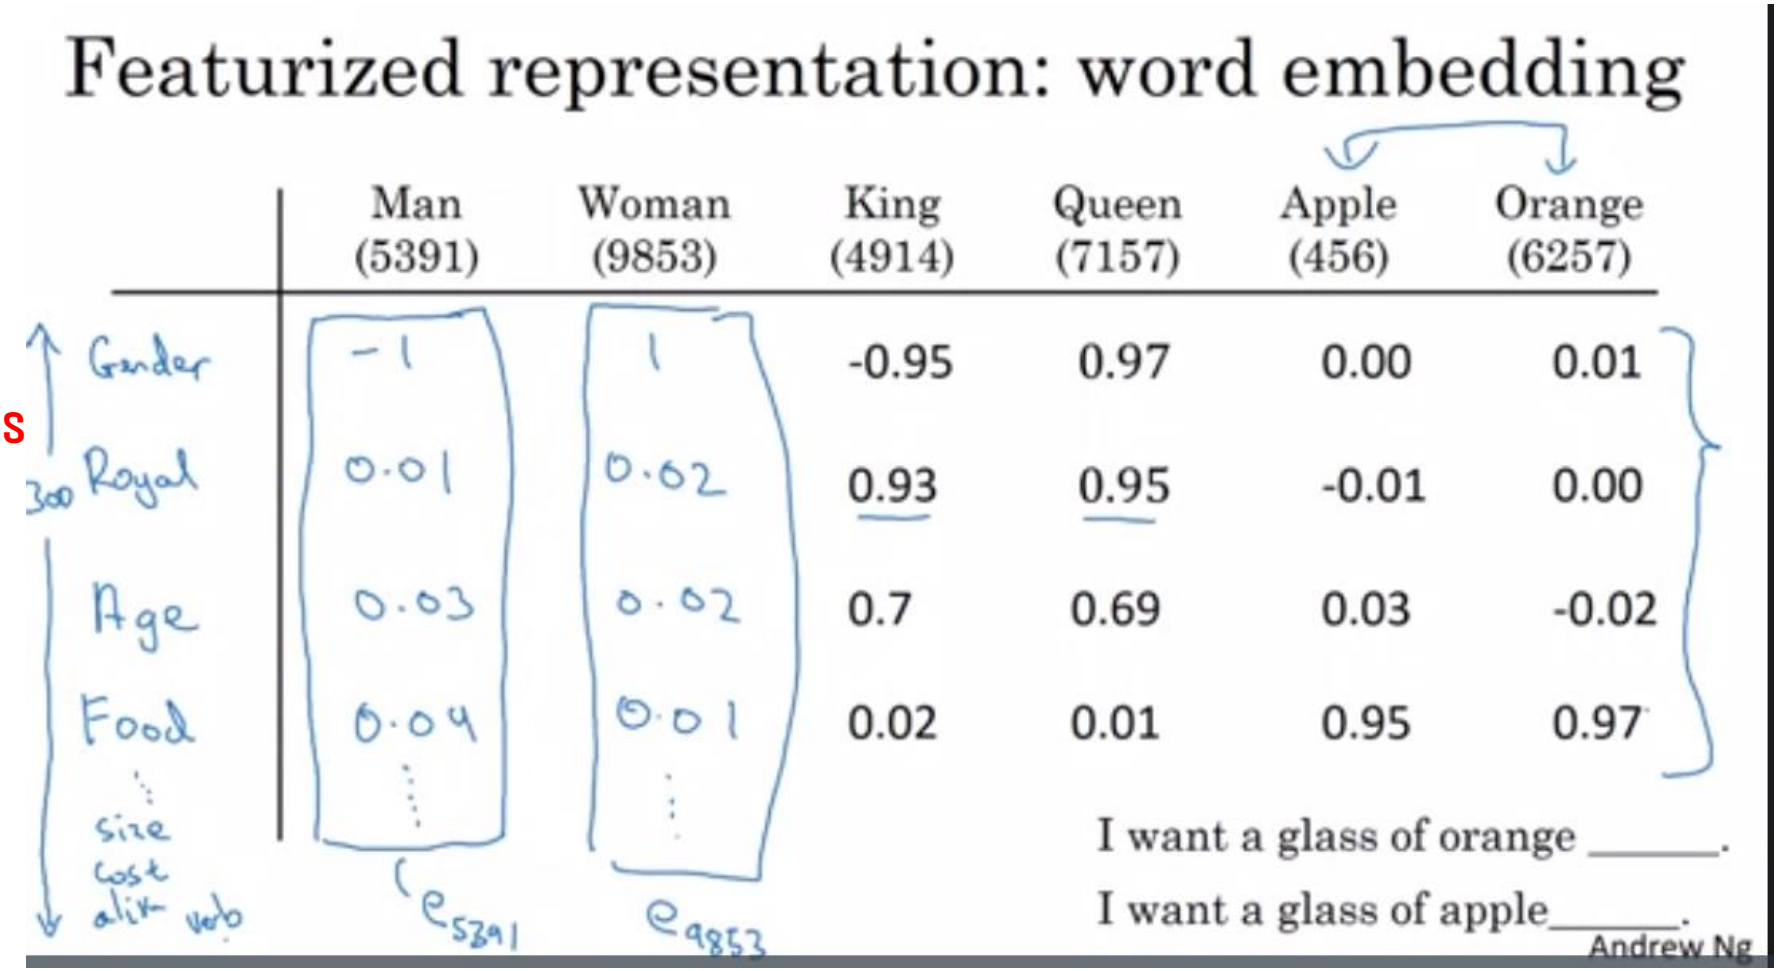

# 단어 벡터

- 단어 벡터
  - 각 단어를 50~300개 정도의 차원으로 구성된 벡터로 표현

    학교 = [0.23, 0.58, 0.97, … , 0.87, 0.95]

    바다 = [0.45, 0.37, 0.81, … , 0.22, 0.64]

- 단어 벡터를 사용하면
  - 각 단어들 사이의 "거리" 를 계산이 가능
  - 거리를 기반으로 유의어/반대어 등을 찾아낼 수 있다
  - 동물의 성별, 단수/복수, 동사/명사를 구분할 수도 있다
  - 그러나 각 벡터 값의 의미는 알 수 없다

# 단어 벡터

- 단어 벡터는 대형 말뭉치로부터 학습
  - 말뭉치의 문장들을 계속 입력하여 학습을 시키면 단어 벡터를 얻을 수 있다
  - 예를 들어 음식과 관련된 다음과 같은 문장들로 학습을 시키면 다음과 같은 단어 벡터를 얻을 수 있을 것이다.
  - 학습에 사용된 문장 예:

"나는 어제 바나나를 맛있게 먹었다"
"이 망고는 먹기가 힘들다"
"이 사과는 씹는 맛이 아주 좋다"
"바나나가 사과보다 맛있다"
"잘 씹어야 맛있게 먹을 수 있다"
…

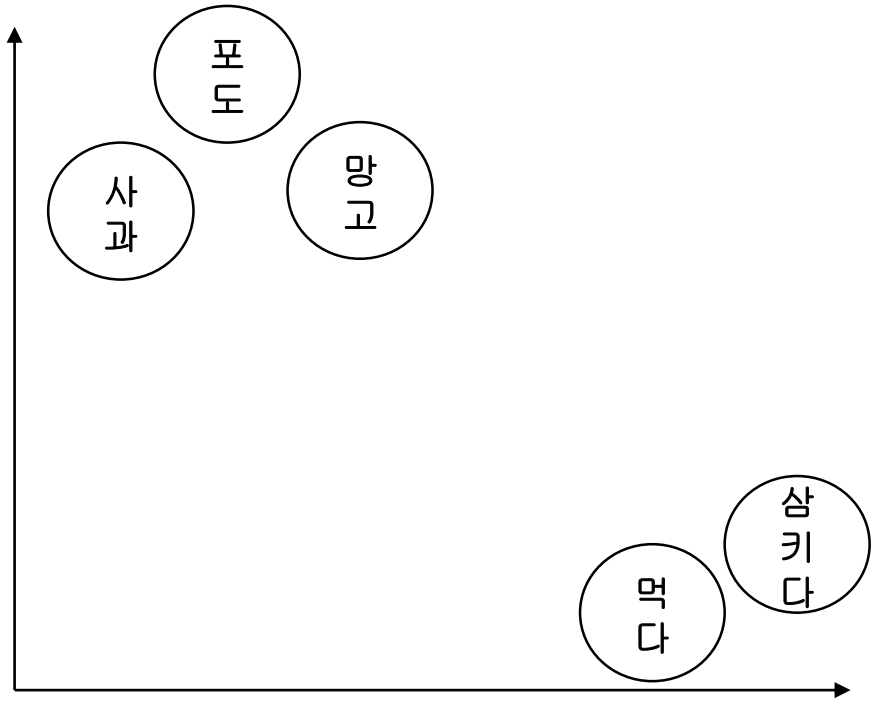

# 단어 벡터

- **이미 만들어져 있는 단어 벡터를 가져다 사용할 수도 있다.**
- **glove**
  - **2014년 스탠포드에서 만든** Global Vectors for Word Representations
  - **위키피디아 데이터로부터 학습**
  - **40만개 단어를 100차원으로 임베딩**
  - npl.stanford.edu/projects/glove **에서 다운로드**

# 단어 벡터

- 단어 벡터를 사용한 A:B = C: ?의 관계를 만족하는 ?를 찾을 수 있다.
  - 왕 : 여왕 = 아들 : ? → ? 부분 : 딸
  - 이러한 연산은 (B-A) 벡터, 즉 (왕 – 여왕) 성분을 구한 후 이를 벡터 C(아들)에 더하면 딸을 구할 수 있다.
  - 이들의 관계는 아래와 같다.

http://word2vec.kr

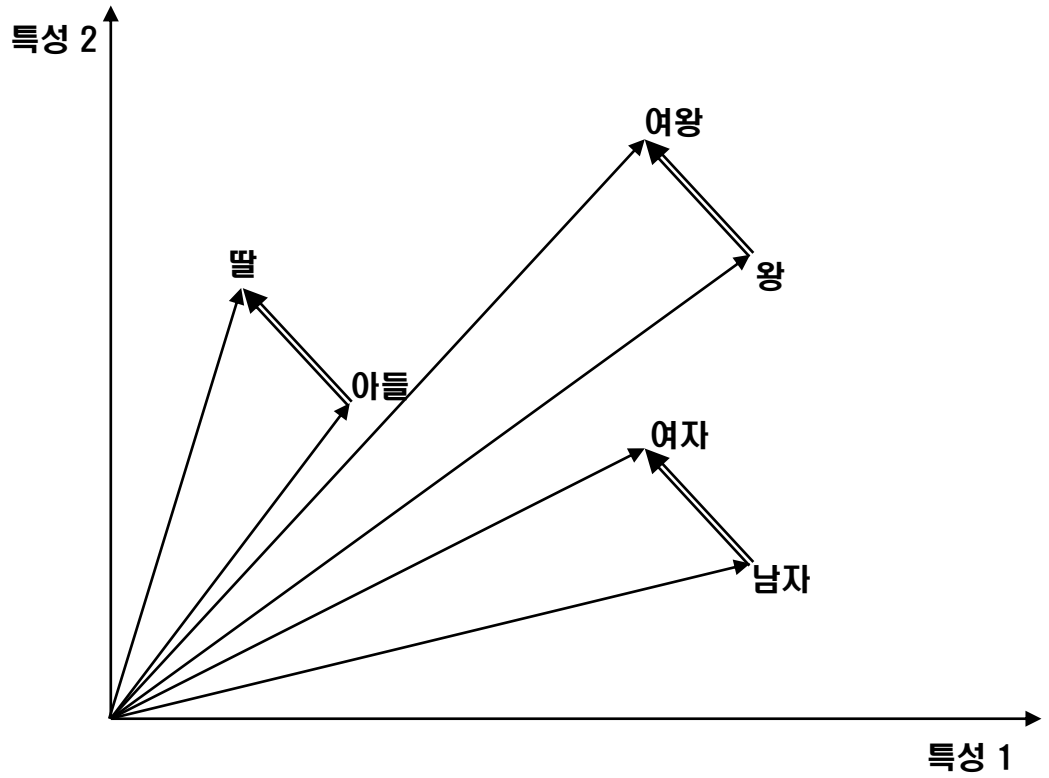

# 단어 벡터 생성

- **단어 벡터 만드는 과정을 소개**
  - **가장 널리 사용되는 라이브러리 : Gensim**
    - pip install gensim

```
from gensim.models.word2vec import Word2Vec
model = Word2Vec(sentense_list, min_count=1)
model.most_similar(positive="조선")

##
[('일본', 0.9953970909118652),
 ('관련', 0.9941188097000122),
 ('인물', 0.9938454031944275),
 ('러시아', 0.9931197166442871),
 ('주요', 0.9918481111526489),
 ('대원군', 0.9915156960487366),
...
```

# 텍스트 처리 – 단어 임베딩

- 문서 단어 행렬
  - 원-핫 인코딩을 사용하여 단어사전 크기의 벡터를 사용
  - 이 벡터는 크기가 매우 크고 희소한 구조
  - 근본적으로 문장 내에서 단어의 존재 여부만 코딩을 함으로써 문장 내에서 단어가 가지고 있는 정보 즉, 문장 구조 정보를 모두 잃어버림

- 단어 임베딩
  - 단어 벡터를 사용하여 단어를 표현하는 방법을 개선
  - 희소 벡터가 아닌 밀집 벡터
  - 단어 벡터를 사용함으로써 id를 구분하는 용도가 아니라 공간상의 점을 매핑함에 따라 단어 사이의 거리를 계산, 단어 간의 관계를 벡터로 표현할 수 있게 됨
  - 자연어 처리, 문서 분류, 감성 분석, 저작 식별, QA, 챗봇 등에서 BoW나 문서 단어 행렬에 비해 높은 성능
  - 텍스트 분석에서 널리 사용

# 3.5 어텐션 기법 – 개념

- CNN과 RNN에서 모두 어텐션 기법이 널리 사용
- 이미지 분석에서는 이미지의 어떤 영역이 이미지 분류에 중요한 역할을 했는지를 파악하는 것이 필요한데, 이 때 사람이 더 집중하여 보는 영역의 개념으로 컴퓨터가 더 중요하게 사용한 부분을 어텐션이라고 부름
- 자연어 처리에서는 긴 문장의 어떤 부분이 문장의 뜻을 파악하는데 더 중요한 역할을 하고 있는지를 파악하는 것을 어텐션 기법으로 처리

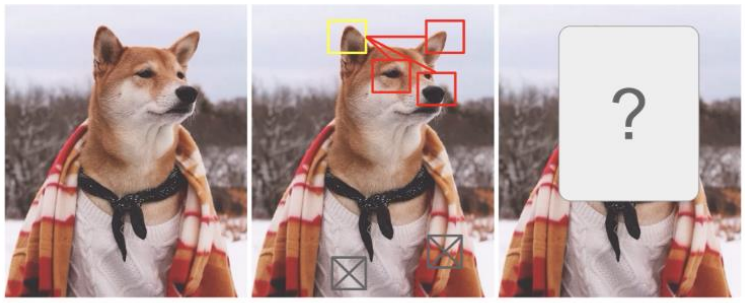


*Fig. 1. A Shiba Inu in a men's outfit. The credit of the original photo goes to Instagram @mensweardog.*

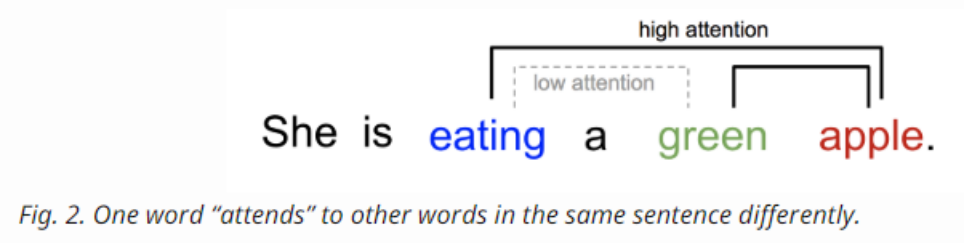


*Fig. 2. One word "attends" to other words in the same sentence differently.*

# 어텐션 기법 – 응용 예 (자동 번역기)

- RNN의 seq2seq 모델을 사용 가정
  - ➢ 디코더는 마지막 단계의 상태값인 h3에만 의존해서 번역
  - ➢ 정보가 매우 제한적
- 문장이 길어지면 오류의 문제가 커진다
  - ➢ 문장 임베딩(sentence embedding)을 수행하여 전체 문장을 하나의 벡터로 만들고 이를 디코더가 사용하는 셈
- 이를 해결하기 위해서 어텐션 기법을 도입
  - ➢ 즉, 중요한 정보에 좀 더 집중하도록 하는 방법

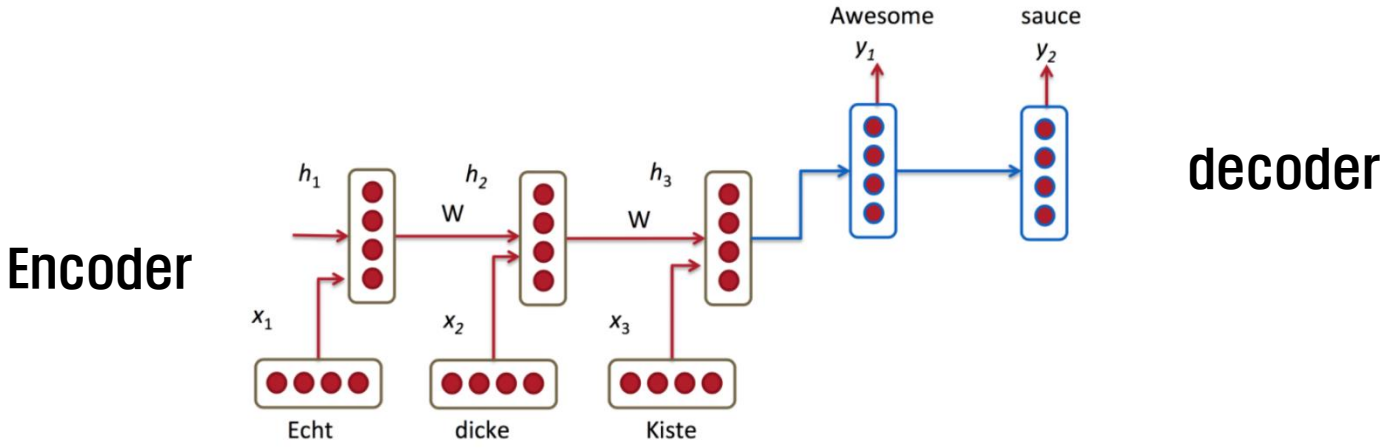

# 어텐션 기법 – 응용 예 (자동 번역기)

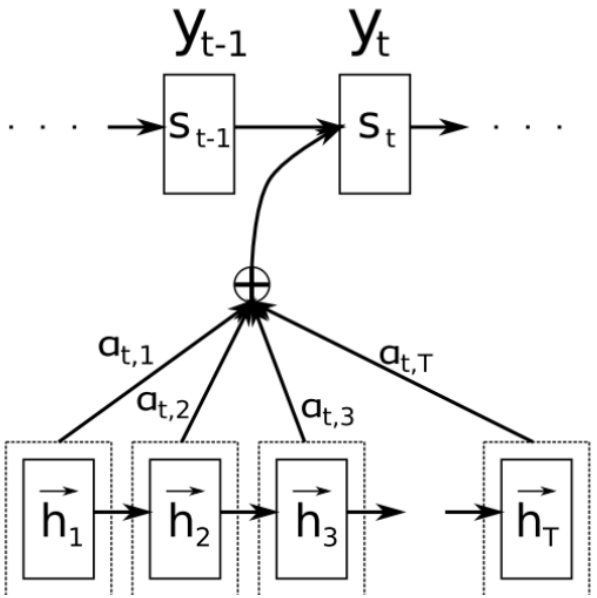


- 이제 디코더는 하나의 상태값에만 의존하는 것이 아니라, 출력을 얻는 각 스텝마다 입력 신호의 다른 부분에 더 주의를 집중할 수 있도록 허용

- 출력은 이제 마지막 스텝의 값만 이용하는 것이 아니라, 모든 스텝의 입력 값의 가중합(weighted sum)을 이용, 즉 shortcut connection 허용.

# 어텐션 기법 – 학습

- 모델은 어느 부분에 주의를 해야 하는지를, 입출력 데이터를 보고, 학습을 통해서 배운다

- 가중치 계수는 전체 합이 1이 되도록 정규화 한다.
  - 이 계수들을 보면 출력이 어떤 부분의 입력에 주의를 하고 있는지를 알 수 있다
  - 즉, 번역을 하면서 어떤 부분의 단어를 중요하게 활용하는지를 알 수 있다

- 입력과 출력의 차원이 증가하면
  - 어텐션 계수의 수가 이들의 곱에 비례하여 증가
  - 어텐션으로 계산량을 줄이고 중요한 곳에 집중해야 효과를 얻는데 잘못하면 모든 경우의 수를 다 고려하게 되어 계산량이 늘어날 수가 있다.

- 직관적으로는 인간의 주의(어텐션)와 상반되지만 이러한 기법은 현재 좋은 성능을 내고 있고 더 발전할 것으로 예상

# 어텐션 기법 – 응용

- 어텐션 기법은 이미지를 보고 이미지를 설명하는 캡션을 자동으로 생성하는 이미지 캡션에서도 사용(https://arxiv.org/abs/1502.03044)
  - 이미지를 인코딩할 때에는 CNN을 사용
  - 캡션을 생성할 때에는 어텐션을 도입한 RNN을 사용

- 어텐션의 종류
  - 글로벌 어텐션 – 전체 step을 모두 사용
  - 로컬 어텐션 : 일부 step만 사용

- align 벡터를 사용하여 인코더와 디코터의 입력을 모두 고려하기도 함

- 셀프 어텐션
  - 순환 구조를 빼고 자신의 어텐션만 사용하는 방법(어텐션의 발전)
  - 성능이 우수하고 RNN을 대체하는 셈

# 3.6 언어 모델링

- BOW(Bag of Words) 는 일종의 특성 추출 방법임. 이는 딥러닝에 사용하기에는 이미 많은 정보를 잃은 상태 – 간단한 머신러닝에서는 아직도 널리 사용되는 기법임.
- RNN 을 이용해서 언어 모델링을 하는 기법 구현.
- 언어모델링이란? 몇 개의 단어가 주어지면 다음에 나올 가장 그럴듯한 (즉, 확률이 높은) 단어를 추천하는 모델
- 자동 번역, 맞춤법 교정, 문장 생성, 저자 스타일 구분 등에 사용

# Q&A